# README - Instrucciones de Ejecución

**INTEGRANTES**:

- ALFREDO MALDONADO
- LUIS RIOS
- CRISTHIAN VELEZ

Fecha: 25 de FEB. de 25

Contenido

1. Objetivo General ..... 3
1.1 Objetivos Específicos ..... 3
2. README - Instrucciones de Ejecución, Descripción del prototipo y del baseline ..... 4
2.1 Requisitos del Dataset ..... 4
2.2 Requisitos Previos (Entorno) ..... 4
2.3 Instalación y Configuración ..... 5
Opción A: Ejecución Local ..... 5
Opción B: Ejecución en Google Colab (Recomendada) ..... 5
2.4 Guía de Uso del Dashboard ..... 6
3. Bibliografía Seleccionada ..... 8

# 1. Objetivo General

Desarrollar un prototipo de sistema de segmentación de clientes utilizando algoritmos de aprendizaje no supervisado (K-Means) para identificar perfiles de consumo diferenciados y optimizar la efectividad de las campañas de marketing en cadenas comerciales del sector retail, permitiendo una transición de estrategias masivas a acciones personalizadas basadas en datos transaccionales, bajo el marco legal de protección de datos en el Ecuador.

## 1.1 Objetivos Específicos

1. **Ejecutar el proceso de extracción, limpieza y preprocesamiento de datos** del historial transaccional en un periodo de dos semanas, calculando las métricas de Recencia, Frecuencia y Valor Monetario (RFM) para construir la base de conocimiento del modelo.y Determinar el número óptimo de clústeres *(k)* mediante la aplicación de técnicas de validación estadística como el Método del Codo y el Coeficiente de Silueta en un plazo de dos semanas, asegurando la cohesión interna y separación de los segmentos identificados.
2. **Implementar y entrenar el algoritmo K-Means** utilizando Python y Scikit-learn durante un ciclo de cinco semanas, logrando una clasificación de la base de clientes en segmentos accionables para el negocio (VIP, Leales, Ocasionales, En Riesgo O Similares).
3. **Construir un dashboard interactivo de visualización** mediante Streamlit en un periodo de tres semanas, que integre los resultados del modelo y permita a los gerentes de marketing explorar las características de cada segmento para el diseño de campañas. y Evaluar el impacto potencial del prototipo mediante la comparación de métricas históricas de conversión contra las proyecciones del modelo.

## 2. README - Instrucciones de Ejecución, Descripción del prototipo y del baseline

Este proyecto es un sistema de segmentación inteligente de clientes para el sector retail. Utiliza análisis RFM (Recencia, Frecuencia y Valor Monetario) combinado con el algoritmo de agrupamiento K-Means para clasificar a los clientes en 4 perfiles accionables (VIP, Leales, En Riesgo, Perdidos). El resultado se visualiza en un dashboard interactivo construido con Streamlit, diseñado para el uso directo por parte de los equipos de marketing.

### 2.1 Requisitos del Dataset

Para que el sistema funcione correctamente, se debe proporcionar un archivo transaccional en formato .csv o .xlsx que contenga, como mínimo, el siguiente registro histórico de ventas:

- Identificador de Cliente (ej. Customer ID o Cedula)
- Fecha de Transacción (ej. Date o Fecha)
- Monto de Transacción (ej. Total Amount o Price o Precio Total)

### 2.2 Requisitos Previos (Entorno)

- Python 3.9 o superior.
- Librerías base: pandas, numpy, scikit-learn, streamlit, plotly.
- (Opcional, solo si se usa Colab) Cuenta activa en ngrok y token de autenticación. Pasos para crear y obtener el authtoken:
    1. Inicia sesión o regístrate en ngrok.
    2. Dirígete a https://dashboard.ngrok.com/get-started/your-authtoken
    3. Copia el "Authtoken" (la cadena alfanumérica proporcionada en esa pantalla) para utilizarlo en el script y habilitar el túnel local.

El sistema está diseñado para ejecutarse en entornos virtualizados (Google Colab) o locales con Python 3.10+.

**Bibliotecas base:**

- pandas (Manipulación de datos tabulares, límite de renderizado extendido a 5,000,000 celdas)
- numpy (Operaciones algebraicas)
- scikit-learn (Modelo K-Means, StandardScaler, Silhouette Score)
- plotly (Visualización topológica 3D)
- streamlit (Framework del Dashboard interactivo)
- pyngrok (Túneles para exposición web desde Google Colab)

## 2.3 Instalación y Configuración

**Opción A: Ejecución Local**

1. Instalar dependencias:
2. pip install streamlit pandas numpy scikit-learn plotly
3. Ejecutar el aplicativo: Asegúrate de tener el código en el archivo app.py y lanza el servidor:
4. streamlit run app.py
5. El dashboard se abrirá automáticamente en tu navegador (por defecto en http://localhost:8501).

**Opción B: Ejecución en Google Colab (Recomendada)**

1. En la primera celda, instala las dependencias e inicia el túnel:
2. Instalar dependencias y pyngrok:

```
!pip install -q streamlit pyngrok pandas numpy scikit-learn
plotly
from pyngrok import ngrok
# Reemplaza con tu token de ngrok
ngrok.set_auth_token('TU_AUTH_TOKEN_AQUI')
public_url = ngrok.connect(8501)
print(f"URL del Dashboard: {public_url}")
```

3. En una segunda celda, escribe el código de la aplicación al archivo app.py:

```
%%writefile app.py
# [Pega aquí el código completo de la v1.7]
```

4. En una tercera celda, levanta el servidor de Streamlit:

```
!streamlit run app.py &>/dev/null&
```

5. Configurar Autenticación (ngrok): Reemplaza el token en tu script de Python para habilitar el túnel:

```
from pyngrok import ngrok
ngrok.set_auth_token("TU_TOKEN_AQUI")
```

6. Ejecutar en segundo plano y obtener URL:

```
# Ejecuta Streamlit en segundo plano
!streamlit run app.py &>/dev/null &
# Conecta el túnel y muestra la URL
public_url = ngrok.connect(8501)
print(f"URL del Dashboard: {public_url}")
```

Haz clic en el enlace generado por ngrok para acceder al dashboard.

## 2.4 Guía de Uso del Dashboard

1. Carga de Datos: En la barra lateral o panel central, arrastra o selecciona tu archivo .csv o .xlsx.
2. Mapeo de Columnas: Usa los menús desplegables para indicar qué columna corresponde al ID del Cliente, a la Fecha y al Monto.
3. Análisis Automático: El sistema calculará la matriz RFM y aplicará el modelo K-Means.
4. Visualización: * Observa el gráfico de barras para entender el volumen de clientes en cada segmento.
    - Explora el mapa de dispersión 3D interactivo para analizar la distribución tridimensional de los clústeres.

5. Acción: Selecciona un segmento en el apartado de "Recomendaciones de Marketing" para obtener estrategias específicas (ej. campañas de retención para clientes "En Riesgo" o programas premium para "VIP").

**Cambios principales v1.8-1.9.**

1. **Modelado Robusto:** El sistema ahora emplea transformaciones logarítmicas (np.log1p) para normalizar el sesgo positivo del historial transaccional, garantizando centroides matemáticamente precisos.
2. **Nuevas Métricas:** Implementación del Índice de Davies-Bouldin para la evaluación combinada de validez interna de los clústeres.
3. **Filtros de Datos:** Prevención de colapsos algorítmicos mediante filtrado automático de montos <= 0.
4. **Motor K-Means:** El modelo ahora equilibra la topología pura de los datos con los requerimientos operativos, aplicando una función de pérdida que pondera las distancias para sugerir un clúster óptimo ajustado a la viabilidad del negocio (priorizando 3 segmentos).
5. **Tratamiento de Datos:** El preprocesamiento implementa transformaciones logarítmicas para normalizar la asimetría típica de ventas minoristas (Ley de Pareto), garantizando agrupaciones por comportamiento real y no por aislamiento de anomalías.
6. **Dashboard y Visualización:** Interfaz mejorada con renderizado 3D en escala logarítmica para análisis de densidades y codificación de colores estática basada en el nivel de fidelidad o riesgo del segmento.

## 3. Bibliografía Seleccionada


1. Paramita, A. S., & Hariguna, T. (2024). Comparative Studies on Clustering Algorithms K-Means and DBSCAN. Journal of Digital Market and Digital Currency. [1]
2. Gan, W., Zhou, P., Wan, S., & Zeng, J. (2025). RFMI-based Customer Segmentation with K-means. 2024 IEEE International Conference on Big Data. [2]
3. John, J. M., Shobayo, O., & Ogunleye, B. (2025). The RFM-A Model: Combining Behavioral and Demographic Data for Segmentation. The Journal of Supercomputing. [3]
4. Srivastava, P., & Saxena, D. S. (2025). Enhanced Customer: A Comparative Analysis of Leading Clustering Algorithms. International Journal of Novel Research and Development, 10(4). [4]
5. Nugroho, B. I., Rafhina, A., & Ananda, P. S. (2024). Customer segmentation in sales transaction data using k-means clustering algorithm. Journal of Intelligent Decision Support System, 7(2). [5]
6. Hidayat, T., Ruldeviyani, A., & Aditama, A. R. (2024). Optimal Use of Customer Segmentation using RFM and K-means. Scientific Journal of Informatics, 11(1). [6]
7. Lai, M. T. (2025). Comparison of K-Means and DBSCAN Algorithms for Customer Segmentation. ResearchGate. [7]
8. Lewaaelhamd, I. (2024). Customer segmentation using machine learning model: An application of RFM analysis. Journal of Data Science and Intelligent Systems, 2, 29–36. [8]
9. Nithyashree, R. (2024). Decoding Decision Support Systems: Empowering Malls with Customer Segmentation. Medium Data Science. [9]
10. Ogunleye, B. (2024). An Exploration of Clustering Algorithms for Customer Segmentation in the UK Retail Market. Analytics, 2(4), 809-823. [10]