README - Instrucciones de Ejecución

INTEGRANTES:

- ALFREDO MALDONADO
- LUIS RIOS
- CRISTHIAN VELEZ

Fecha: 25 de FEB. de 26

Contenido

1. Objetivo General 3
1.1 Objetivos Específicos 3
2. README - Instrucciones de Ejecución, Descripción del prototipo y del baseline 4
2.1 Requisitos del Dataset 4
2.2 Requisitos Previos (Entorno) 4
2.3 Instalación y Configuración 5
Opción A: Ejecución Local 5
Opción B: Ejecución en Google Colab (Recomendada) 5
2.4 Guía de Uso del Dashboard 6
3. Bibliografía Seleccionada 8

1. Objetivo General

Desarrollar un prototipo de sistema de segmentación de clientes utilizando algoritmos de aprendizaje no supervisado (K-Means) para identificar perfiles de consumo diferenciados y optimizar la efectividad de las campañas de marketing en cadenas comerciales del sector retail, permitiendo una transición de estrategias masivas a acciones personalizadas basadas en datos transaccionales, bajo el marco legal de protección de datos en el Ecuador.

1.1 Objetivos Específicos

1. **Ejecutar el proceso de extracción, limpieza y preprocesamiento de datos** del historial transaccional en un periodo de dos semanas, calculando las métricas de Recencia, Frecuencia y Valor Monetario (RFM) para construir la base de conocimiento del modelo.y Determinar el número óptimo de clústeres *(k)* mediante la aplicación de técnicas de validación estadística como el Método del Codo y el Coeficiente de Silueta en un plazo de dos semanas, asegurando la cohesión interna y separación de los segmentos identificados.
2. **Implementar y entrenar el algoritmo K-Means** utilizando Python y Scikit-learn durante un ciclo de cinco semanas, logrando una clasificación de la base de clientes en segmentos accionables para el negocio (VIP, Leales, Ocasionales, En Riesgo O Similares).
3. **Construir un dashboard interactivo de visualización** mediante Streamlit en un periodo de tres semanas, que integre los resultados del modelo y permita a los gerentes de marketing explorar las características de cada segmento para el diseño de campañas. y Evaluar el impacto potencial del prototipo mediante la comparación de métricas históricas de conversión contra las proyecciones del modelo.

2. README - Instrucciones de Ejecución, Descripción del prototipo y del baseline

Este proyecto es un sistema de segmentación inteligente de clientes para el sector retail. Utiliza análisis RFM (Recencia, Frecuencia y Valor Monetario) combinado con el algoritmo de agrupamiento K-Means para clasificar a los clientes en 4 perfiles accionables (VIP, Leales, En Riesgo, Perdidos). El resultado se visualiza en un dashboard interactivo construido con Streamlit, diseñado para el uso directo por parte de los equipos de marketing.

2.1 Requisitos del Dataset

Para que el sistema funcione correctamente, se debe proporcionar un archivo transaccional en formato .csv o .xlsx que contenga, como mínimo, el siguiente registro histórico de ventas:

- Identificador de Cliente (ej. Customer ID o Cedula)
- Fecha de Transacción (ej. Date o Fecha)
- Monto de Transacción (ej. Total Amount o Price o Precio Total)

2.2 Requisitos Previos (Entorno)

- Python 3.9 o superior.
- Librerías base: pandas, numpy, scikit-learn, streamlit, plotly.
- (Opcional, solo si se usa Colab) Cuenta activa en ngrok y token de autenticación. Pasos para crear y obtener el authtoken:
    1. Inicia sesión o regístrate en ngrok.
    2. Dirígete a https://dashboard.ngrok.com/get-started/your-authtoken
    3. Copia el "Authtoken" (la cadena alfanumérica proporcionada en esa pantalla) para utilizarlo en el script y habilitar el túnel local.

El sistema está diseñado para ejecutarse en entornos virtualizados (Google Colab) o locales con Python 3.10+.

Bibliotecas base:

- pandas (Manipulación de datos tabulares, límite de renderizado extendido a 5,000,000 celdas)
- numpy (Operaciones algebraicas)
- scikit-learn (Modelo K-Means, StandardScaler, Silhouette Score)
- plotly (Visualización topológica 3D)
- streamlit (Framework del Dashboard interactivo)
- pyngrok (Túneles para exposición web desde Google Colab)

2.3 Instalación y Configuración

Opción A: Ejecución Local

1. Instalar dependencias:
2. pip install streamlit pandas numpy scikit-learn plotly
3. Ejecutar el aplicativo: Asegúrate de tener el código en el archivo app.py y lanza el servidor:
4. streamlit run app.py
5. El dashboard se abrirá automáticamente en tu navegador (por defecto en http://localhost:8501).

Opción B: Ejecución en Google Colab (Recomendada)

1. En la primera celda, instala las dependencias e inicia el túnel:
2. Instalar dependencias y pyngrok:

```
!pip install -q streamlit pyngrok pandas numpy scikit-learn
plotly
from pyngrok import ngrok
# Reemplaza con tu token de ngrok
ngrok.set_auth_token('TU_AUTH_TOKEN_AQUI')
public_url = ngrok.connect(8501)
print(f"URL del Dashboard: {public_url}")
```

3. En una segunda celda, escribe el código de la aplicación al archivo app.py:

```
%%writefile app.py
# [Pega aquí el código completo de la v1.7]
```

4. En una tercera celda, levanta el servidor de Streamlit:

```
!streamlit run app.py &>/dev/null&
```

5. Configurar Autenticación (ngrok): Reemplaza el token en tu script de Python para habilitar el túnel:

```
from pyngrok import ngrok
ngrok.set_auth_token("TU_TOKEN_AQUI")
```

6. Ejecutar en segundo plano y obtener URL:

```
# Ejecuta Streamlit en segundo plano
!streamlit run app.py &>/dev/null &
# Conecta el túnel y muestra la URL
public_url = ngrok.connect(8501)
print(f"URL del Dashboard: {public_url}")
```

Haz clic en el enlace generado por ngrok para acceder al dashboard.

2.4 Guía de Uso del Dashboard

1. Carga de Datos: En la barra lateral o panel central, arrastra o selecciona tu archivo .csv o .xlsx.
2. Mapeo de Columnas: Usa los menús desplegables para indicar qué columna corresponde al ID del Cliente, a la Fecha y al Monto.
3. Análisis Automático: El sistema calculará la matriz RFM y aplicará el modelo K-Means.
4. Visualización: * Observa el gráfico de barras para entender el volumen de clientes en cada segmento.
    - Explora el mapa de dispersión 3D interactivo para analizar la distribución tridimensional de los clústeres.

5. Acción: Selecciona un segmento en el apartado de "Recomendaciones de Marketing" para obtener estrategias específicas (ej. campañas de retención para clientes "En Riesgo" o programas premium para "VIP").

Cambios principales v1.8-1.9.

1. **Modelado Robusto:** El sistema ahora emplea transformaciones logarítmicas (np.log1p) para normalizar el sesgo positivo del historial transaccional, garantizando centroides matemáticamente precisos.
2. **Nuevas Métricas:** Implementación del Índice de Davies-Bouldin para la evaluación combinada de validez interna de los clústeres.
3. **Filtros de Datos:** Prevención de colapsos algorítmicos mediante filtrado automático de montos <= 0.
4. **Motor K-Means:** El modelo ahora equilibra la topología pura de los datos con los requerimientos operativos, aplicando una función de pérdida que pondera las distancias para sugerir un clúster óptimo ajustado a la viabilidad del negocio (priorizando 3 segmentos).
5. **Tratamiento de Datos:** El preprocesamiento implementa transformaciones logarítmicas para normalizar la asimetría típica de ventas minoristas (Ley de Pareto), garantizando agrupaciones por comportamiento real y no por aislamiento de anomalías.
6. **Dashboard y Visualización:** Interfaz mejorada con renderizado 3D en escala logarítmica para análisis de densidades y codificación de colores estática basada en el nivel de fidelidad o riesgo del segmento.

3. Bibliografía Seleccionada

1. Paramita, A. S., & Hariguna, T. (2024). Comparative Studies on Clustering Algorithms K-Means and DBSCAN. Journal of Digital Market and Digital Currency. [1]
2. Gan, W., Zhou, P., Wan, S., & Zeng, J. (2025). RFMI-based Customer Segmentation with K-means. 2024 IEEE International Conference on Big Data. [2]
3. John, J. M., Shobayo, O., & Ogunleye, B. (2025). The RFM-A Model: Combining Behavioral and Demographic Data for Segmentation. The Journal of Supercomputing. [3]
4. Srivastava, P., & Saxena, D. S. (2025). Enhanced Customer: A Comparative Analysis of Leading Clustering Algorithms. International Journal of Novel Research and Development, 10(4). [4]
5. Nugroho, B. I., Rafhina, A., & Ananda, P. S. (2024). Customer segmentation in sales transaction data using k-means clustering algorithm. Journal of Intelligent Decision Support System, 7(2). [5]
6. Hidayat, T., Ruldeviyani, A., & Aditama, A. R. (2024). Optimal Use of Customer Segmentation using RFM and K-means. Scientific Journal of Informatics, 11(1). [6]
7. Lai, M. T. (2025). Comparison of K-Means and DBSCAN Algorithms for Customer Segmentation. ResearchGate. [7]
8. Lewaaelhamd, I. (2024). Customer segmentation using machine learning model: An application of RFM analysis. Journal of Data Science and Intelligent Systems, 2, 29–36. [8]
9. Nithyashree, R. (2024). Decoding Decision Support Systems: Empowering Malls with Customer Segmentation. Medium Data Science. [9]
10. Ogunleye, B. (2024). An Exploration of Clustering Algorithms for Customer Segmentation in the UK Retail Market. Analytics, 2(4), 809-823. [10]