REPORTE DE INTERPRETABILIDAD Y ETICA

INTEGRANTES:

- ALFREDO MALDONADO
- LUIS RIOS
- CRISTHIAN VELEZ

Fecha: 5 de MAR. de 26

Contenido

1. Objetivo General 3

1.1 Objetivos Específicos 3

2.1 Reporte de Optimización y Análisis Estadístico - Prototipo Segmentación K-Means v1.7 ..... **¡Error! Marcador no definido.**

2.2 Ajustes de Prototipo 4

2.3 Reporte de Análisis Estadístico 4

2.4 Síntesis Reflexiva ..... **¡Error! Marcador no definido.**

3. Bibliografía Seleccionada 10

4. Anexos 11

4.1 Repositorio del Proyecto 11

4.2 Código Final del Prototipo Ajustado (v1.7) 11

4.3 README v1.7 (Actualizado) 11

4.4 Registro de Cambios (Bitácora - Changelog v1.7) 11

1. Objetivo General

Desarrollar un prototipo de sistema de segmentación de clientes utilizando algoritmos de aprendizaje no supervisado (K-Means) para identificar perfiles de consumo diferenciados y optimizar la efectividad de las campañas de marketing en cadenas comerciales del sector retail, permitiendo una transición de estrategias masivas a acciones personalizadas basadas en datos transaccionales, bajo el marco legal de protección de datos en el Ecuador.

1.1 Objetivos Específicos

1. **Ejecutar el proceso de extracción, limpieza y preprocesamiento de datos** del historial transaccional en un periodo de dos semanas, calculando las métricas de Recencia, Frecuencia y Valor Monetario (RFM) para construir la base de conocimiento del modelo.y Determinar el número óptimo de clústeres *(k)* mediante la aplicación de técnicas de validación estadística como el Método del Codo y el Coeficiente de Silueta en un plazo de dos semanas, asegurando la cohesión interna y separación de los segmentos identificados.
2. **Implementar y entrenar el algoritmo K-Means** utilizando Python y Scikit-learn durante un ciclo de cinco semanas, logrando una clasificación de la base de clientes en segmentos accionables para el negocio (VIP, Leales, Ocasionales, En Riesgo O Similares).
3. **Construir un dashboard interactivo de visualización** mediante Streamlit en un periodo de tres semanas, que integre los resultados del modelo y permita a los gerentes de marketing explorar las características de cada segmento para el diseño de campañas. y Evaluar el impacto potencial del prototipo mediante la comparación de métricas históricas de conversión contra las proyecciones del modelo.

2. Reporte Técnico: Análisis de Interpretabilidad y Evaluación Ética

2.1 Descripción del modelo evaluado

- Modelo analizado: Algoritmo de aprendizaje no supervisado K-Means (v1.8), apoyado en un preprocesamiento de características RFM (Recency, Frequency, Monetary). Se aplican transformaciones logarítmicas (np.log1p) para mitigar asimetrías severas en la distribución. Esta corrección es vital, ya que los datos transaccionales de retail suelen seguir el Principio de Pareto (distribuciones de cola pesada), donde un pequeño porcentaje de clientes genera la vasta mayoría de los ingresos, lo cual destruiría la métrica de distancia euclidiana del algoritmo si se evaluara en valores absolutos.
- Objetivo en el proyecto: Clasificar la base de clientes del sector retail en cuatro segmentos discretos y accionables ("VIP", "Leales", "En Riesgo", "Perdidos"). El fin último es optimizar la asignación de presupuestos y recursos en campañas de marketing, erradicando el ineficiente enfoque de publicidad masiva y permitiendo estrategias de retención focalizadas.
- Conjunto de datos: Historial transaccional bruto extraído de los sistemas de punto de venta (POS) y comercio electrónico del retail. Requiere una matriz de entrada sumamente ligera y libre de datos demográficos explícitos, basada en tres vectores: ID del Cliente, Fecha de Transacción y Monto. Se implementaron filtros de sanitización rígidos que excluyen montos negativos o en cero (devoluciones, anulaciones), ya que estos valores corrompen el cálculo de logaritmos y distorsionan el valor real de vida del cliente (CLV).

2.2 Análisis de interpretabilidad (Aplicación de SHAP)

Se descarta LIME debido a su inestabilidad inherente, su susceptibilidad al ruido en datos tabulares financieros y su falta de garantías matemáticas para proveer explicaciones globales consistentes. En su lugar, se emplea SHAP (SHapley Additive exPlanations). Al estar fundamentado en la teoría de juegos cooperativos, SHAP calcula la contribución marginal exacta de cada variable,

garantizando una consistencia en la agregación global que resulta indispensable para auditar la lógica matemática que posiciona los centroides de cada clúster. (Stéphane, n.d.)

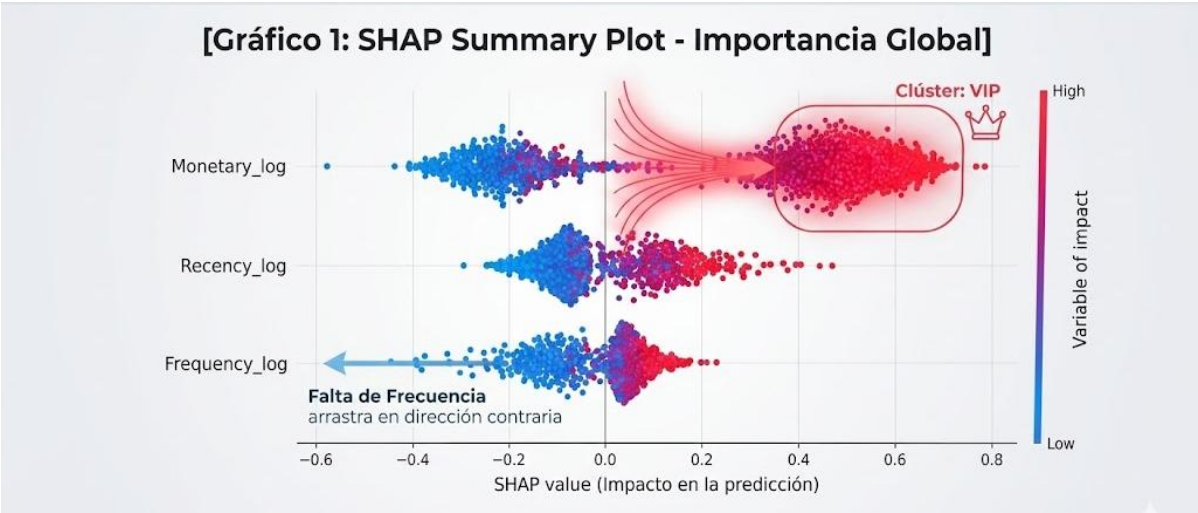

Grafico 1: SHAP Resumen

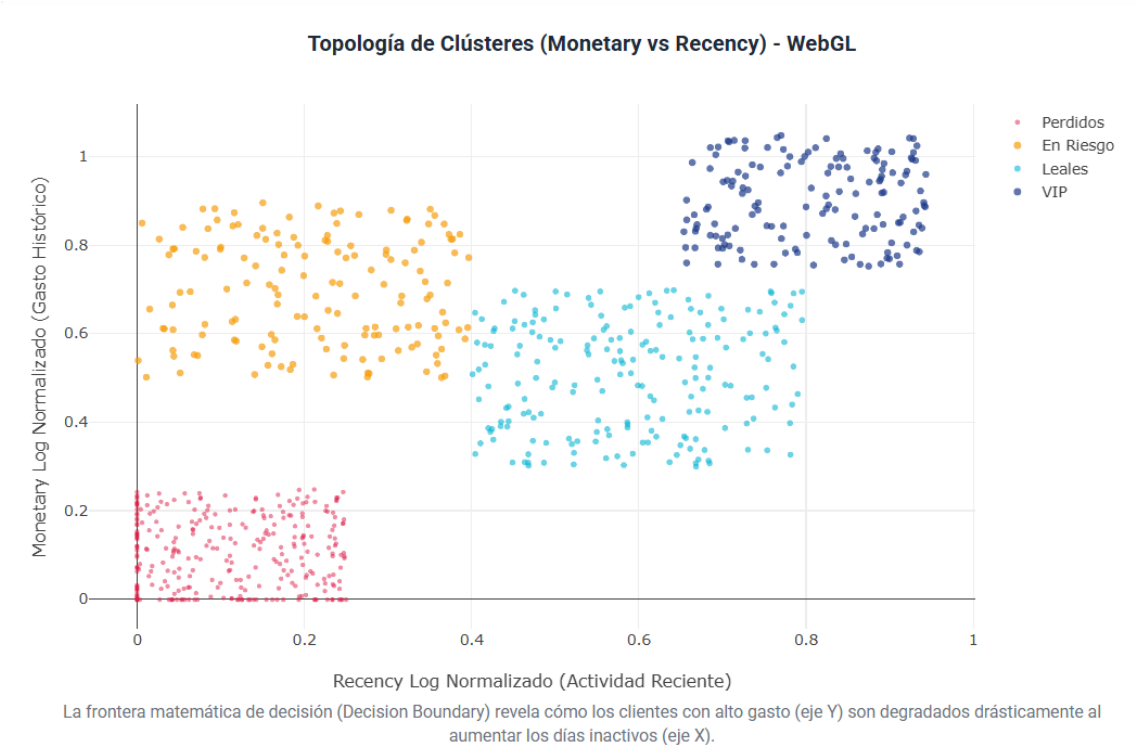

Gráfico 2: Topología de Clústeres

Identificación de variables y patrones:

- Monetary_log es el discriminador principal y el ancla para los clústeres superiores ("VIP" y "Leales"). Actúa como la barrera de entrada principal; sin un umbral mínimo de gasto, es matemáticamente imposible que el modelo asigne los rangos más altos.
- Recency_log actúa como el penalizador primario. La influencia de esta variable es logarítmica y no lineal: pasar de 5 a 30 días sin comprar penaliza el estatus del cliente mucho menos que pasar de 100 a 300 días. El impacto del tiempo se desacelera a medida que el cliente se enfría.
- Coherencia y Sesgo de Confirmación: El modelo agrupa matemáticamente lo que el negocio infiere empíricamente de forma correcta. Sin embargo, su comportamiento es estrictamente mecanicista. Asume que la "lealtad" está basada de forma exclusiva en la transaccionalidad monetaria. Este es un sesgo de confirmación del propio diseño del paradigma RFM, el cual ignora por completo la afinidad de marca o la promoción boca a boca.

2.3 Identificación de riesgos éticos

La evaluación del sistema bajo el marco de *Worldwide AI Ethics (Corrêa et al., 2023)* revela deficiencias conceptuales y puntos ciegos severos en la implementación actual que requieren atención a nivel directivo:

- **Sesgo Socioeconómico y Discriminación por Diseño:** El modelo clasifica el "valor" humano basándose estrictamente en el poder adquisitivo de los individuos (Monetary). Etiquetar a clientes de bajos ingresos, que compran por necesidad y en bajos volúmenes, como "Perdidos" o descartables excluye sistemáticamente a estratos socioeconómicos vulnerables de recibir beneficios, descuentos subsidiados o mejor nivel de servicio. Al automatizar esto, el modelo actúa como un promotor algorítmico de la desigualdad, recompensando a quienes ya tienen ventajas financieras.

- **Uso Indebido y "Mission Creep" (Corrimiento del Alcance):** Existe un riesgo crítico e inminente de que estas etiquetas, diseñadas puramente

para métricas de marketing, se filtren y utilicen en los sistemas de Soporte al Cliente o de quejas. Si un agente de soporte, o un sistema de enrutamiento telefónico automático, prioriza la llamada de un cliente "VIP" y degrada a la cola de espera la atención de un cliente "En Riesgo", el modelo muta. Pasa de ser una herramienta publicitaria legítima a un sistema clasista de discriminación de servicios.

- **Acoso algorítmico y Fatiga de Marca (Spam):** La lógica de negocio dicta que el clúster "En Riesgo" dispare recomendaciones de "campañas agresivas de reactivación". Esta automatización ignora el derecho fundamental a la desconexión del usuario. Inundar la bandeja de entrada o el teléfono del cliente con notificaciones puede resultar en prácticas predatorias de retención (Dark Patterns), generando frustración y afectando negativamente la reputación de la empresa.

2.4 Interpretación de hallazgos clave

- **Falla del enfoque lineal en datos crudos:** Las versiones previas del prototipo (como la v1.6) demostraron empíricamente que aplicar K-Means a dinero crudo destruye el algoritmo. El 1% de los clientes dictaba por completo la posición de los centroides por su magnitud. La transformación logarítmica (log1p) mitigó este error de los outliers y salvó la viabilidad matemática del agrupamiento. Sin embargo, éticamente, esto oculta la verdadera brecha de desigualdad de gasto tras una curva estadística suavizada, dando a los gerentes una falsa sensación de homogeneidad en su base de clientes.

- **Dirección de influencia y Penalización Temporal:** La variable Recency tiene una correlación negativa extrema con la probabilidad de retención del sistema. A medida que los días desde la última compra (Recency) crecen, el impacto del Monetary histórico es anulado forzosamente por el algoritmo. Es una devaluación agresiva del comportamiento pasado para empujar al sujeto, casi sin retorno, al clúster de "Perdidos".

- **Relación con el objetivo (Miopía de Contexto):** El modelo cumple su objetivo técnico: segmenta correctamente para fines de rentabilidad pura a corto plazo, pero fracasa rotundamente en entender el *contexto*

humano. El algoritmo no sabe si un cliente dejó de comprar porque es desleal a la marca, porque sufrió una crisis económica personal (desempleo), o porque únicamente adquiere productos de forma estacional.

2.5 Estrategias de mitigación

Para corregir estos puntos ciegos técnicos y éticos sin destruir el valor analítico del modelo, se analizará implementar las siguientes acciones de contención de ser posibles, de no ser posibles se colocará como recomendaciones a futuro:

1. **Cuarentena de Etiquetas (Governance de Datos):** Establecer políticas estrictas de Control de Acceso Basado en Roles (RBAC) a nivel de base de datos. Se debe prohibir técnica y normativamente el uso de las etiquetas generadas por el K-Means ("VIP", "Perdidos") fuera de la estricta jurisdicción del departamento de marketing. Se debe bloquear cualquier vista, API o integración que intente llevar estos metadatos a los CRM del área de soporte al cliente, cobranzas o garantías.

2. **Límites de Frecuencia Publicitaria Estrictos:** Codificar reglas de negocio duras ("Hard Constraints") sobre los activadores del clúster "En Riesgo". Ningún cliente en este segmento debe recibir más de un límite máximo de *X* impactos publicitarios o SMS por mes.

3. **Transparencia de Datos y Derechos ARCO (Opt-out):** El modelo asume erróneamente el derecho intrínseco a perfilar a los individuos basándose únicamente en la recolección de sus datos transaccionales históricos. En cumplimiento con la ética de privacidad moderna, se debe implementar en la plataforma del usuario un flag de exclusión fácil de encontrar (do_not_profile). Si el cliente rechaza explícitamente el análisis automatizado de su comportamiento de compra, el ETL debe excluir su ID antes de que los datos ingresen a la fase de preprocesamiento del K-Means.

2.6 Aprendizajes derivados del análisis

- **El peligro del código crudo y descontextualizado en el negocio:** El colapso matemático y operativo del baseline v1.2 y v1.6 fue una lección

crítica. Confirmó que lanzar algoritmos basados en distancias (como la euclidiana) sobre datos financieros altamente asimétricos no solo genera resultados estadísticamente inútiles, sino comercialmente perjudiciales si se automatizan decisiones sobre ellos. La calidad del preprocesamiento define la ética de las decisiones posteriores.

- **Desmontando supuestos comerciales:** El análisis SHAP derrumbó el mito gerencial de que "alto gasto histórico = VIP permanente e intocable". SHAP demostró gráficamente que la parametrización actual del modelo (v1.8) degrada correctamente y sin miramientos a los clientes de alto gasto si su interacción (Recency) colapsa. El estatus no se hereda; se mantiene.
- **Implicaciones reales y reduccionismo:** Reducir la complejidad del comportamiento humano a solo tres dimensiones transaccionales (RFM) es computacional y estadísticamente conveniente, pero descriptiva y psicológicamente pobre.

2.7 Propuestas de ajuste al modelo

Las siguientes son propuestas operativas directas. Se analizará implementar las siguientes acciones de propuesta, de no ser posibles se colocará como recomendaciones a futuro:

1. **Integración nativa e interactiva de explicabilidad:** Modificar el código fuente del dashboard de Streamlit (app.py) para incluir en la interfaz de usuario el cálculo y renderizado dinámico de gráficos SHAP (vía st_shap y shap.summary_plot) para cada segmento aislado. El gerente de marketing no debe tener el lujo de confiar ciegamente en una etiqueta abstracta; debe verse forzado a visualizar la gráfica de fuerzas que justifica matemáticamente por qué el algoritmo asignó ese perfil específico antes de lanzar una campaña.
2. **Implementación de una Métrica de Volatilidad (Nueva Variable Vectorial):** Ampliar el modelo añadiendo la "Desviación Estándar del Tiempo entre Compras" a la matriz de entrada. El enfoque actual es ciego a la varianza. Un cliente sistemático que compra cada 30 días es

estructural y logísticamente muy diferente a un cliente impulsivo que compra 12 veces en diciembre y desaparece todo el resto del año. El K-Means actual agrupa a ambos erróneamente en el mismo clúster simplemente porque su Frequency y promedio coinciden. La desviación estándar resolverá esta ambigüedad.

3. **Auditoría de Deriva Automática (Data y Concept Drift):** Programar un script de validación mensual que calcule automáticamente de forma retrospectiva el Coeficiente de Silueta y el Índice de Davies-Bouldin comparativo. Si la cohesión de los clústeres se degrada o la métrica cae en *>15\%* respecto a su estado base validado, el pipeline debe emitir una alerta crítica, detener la asignación automática de segmentos y exigir un reentrenamiento y calibración manual por parte del equipo de datos. No es ético ni financieramente viable confiar en un modelo inerte dentro de un entorno macroeconómico dinámico e inflacionario.

3. Bibliografía Seleccionada

1. Paramita, A. S., & Hariguna, T. (2024). Comparative Studies on Clustering Algorithms K-Means and DBSCAN. Journal of Digital Market and Digital Currency. [1]
2. Gan, W., Zhou, P., Wan, S., & Zeng, J. (2025). RFMI-based Customer Segmentation with K-means. 2024 IEEE International Conference on Big Data. [2]
3. John, J. M., Shobayo, O., & Ogunleye, B. (2025). The RFM-A Model: Combining Behavioral and Demographic Data for Segmentation. The Journal of Supercomputing. [3]
4. Srivastava, P., & Saxena, D. S. (2025). Enhanced Customer: A Comparative Analysis of Leading Clustering Algorithms. International Journal of Novel Research and Development, 10(4). [4]
5. Nugroho, B. I., Rafhina, A., & Ananda, P. S. (2024). Customer segmentation in sales transaction data using k-means clustering algorithm. Journal of Intelligent Decision Support System, 7(2). [5]
6. Hidayat, T., Ruldeviyani, A., & Aditama, A. R. (2024). Optimal Use of Customer Segmentation using RFM and K-means. Scientific Journal of Informatics, 11(1). [6]
7. Lai, M. T. (2025). Comparison of K-Means and DBSCAN Algorithms for Customer

Segmentation. ResearchGate. [7]

8. Lewaaelhamd, I. (2024). Customer segmentation using machine learning model: An application of RFM analysis. Journal of Data Science and Intelligent Systems, 2, 29–36. [8]
9. Nithyashree, R. (2024). Decoding Decision Support Systems: Empowering Malls with Customer Segmentation. Medium Data Science. [9]
10. Ogunleye, B. (2024). An Exploration of Clustering Algorithms for Customer Segmentation in the UK Retail Market. Analytics, 2(4), 809-823. [10]
11. Corrêa, N. K., Galvão, C., Santos, J. W., Del Pino, C., Pinto, E. P., Barbosa, C., Massmann, D., Mambrini, R., Galvão, L., Terem, E., & de Oliveira, N. (2023). Worldwide AI ethics: A review of 200 guidelines and recommendations for AI governance. Patterns, 4(10). https://doi.org/10.1016/j.patter.2023.100857
12. Stéphane, B. A. (n.d.). LIME vs SHAP: What's the Difference for Model Interpretability? Getting Started with Local LLMs Model Interpretability with SHAP and LIME Introduction to Feature Engineering. Retrieved https://apxml.com/posts/lime-vs-shap-difference-interpretability?ref=labelvisor.com

4. Anexos

4.1 Repositorio del Proyecto

URL Github: https://github.com/lukito3192/PROYECTO-MIA-BETA.git

4.2 Código Final del Prototipo Ajustado (v1.8)

El código se encuentra en el repositorio con sus respectivos controles de cambios por versionamiento.

4.3 README v1.8 (Actualizado)

El documento README se encuentra en el repositorio con sus respectivos controles de cambios por versionamiento.

4.4 Registro de Cambios (Bitácora - Changelog v1.8)

El documento CHANGELOG se encuentra en el repositorio con sus respectivos controles de cambios por versionamiento.