Resultados Prototipo.

INTEGRANTES:

- ALFREDO MALDONADO
- LUIS RIOS
- CRISTHIAN VELEZ

Fecha: 20 de Mar. de 26

Contenido

1. Objetivo General 3

1.1 Objetivos Específicos 3

2. Registro de Iteraciones del Prototipo 4

2.1 Versión 1.0 y 1.1: Intento Inicial e Implementación de Arquitectura Base 4

2.2 Versión 1.2: Implementación de K-Means y Falla Metodológica (K Fijo) 5

2.3 Versión 1.3 y 1.4: Parametrización Manual y Mejoras de Interfaz 7

2.4 Versión 1.5 y 1.6: Cálculo Automático de K Óptimo y Validación Visual 11

2.5 Versión 1.7: Introducción del Coeficiente Silhouette y Validación de Datos 13

2.6 Versión 1.8: Cross-Validación con Índice Davies-Bouldin 15

2.7 Versión 1.9: Penalización Matemática y Alineación Comercial (K=3) 18

3. Conclusión General del Anexo 21

4. Bibliografía Seleccionada 22

1. Objetivo General

Desarrollar un prototipo de sistema de segmentación de clientes utilizando algoritmos de aprendizaje no supervisado (K-Means) para identificar perfiles de consumo diferenciados y optimizar la efectividad de las campañas de marketing en cadenas comerciales del sector retail, permitiendo una transición de estrategias masivas a acciones personalizadas basadas en datos transaccionales, bajo el marco legal de protección de datos en el Ecuador.

1.1 Objetivos Específicos

1. **Ejecutar el proceso de extracción, limpieza y preprocesamiento de datos** del historial transaccional en un periodo de dos semanas, calculando las métricas de Recencia, Frecuencia y Valor Monetario (RFM) para construir la base de conocimiento del modelo.y Determinar el número óptimo de clústeres *(k)* mediante la aplicación de técnicas de validación estadística como el Método del Codo y el Coeficiente de Silueta en un plazo de dos semanas, asegurando la cohesión interna y separación de los segmentos identificados.
2. **Implementar y entrenar el algoritmo K-Means** utilizando Python y Scikit-learn durante un ciclo de cinco semanas, logrando una clasificación de la base de clientes en segmentos accionables para el negocio (VIP, Leales, Ocasionales, En Riesgo O Similares).
3. **Construir un dashboard interactivo de visualización** mediante Streamlit en un periodo de tres semanas, que integre los resultados del modelo y permita a los gerentes de marketing explorar las características de cada segmento para el diseño de campañas. y Evaluar el impacto potencial del prototipo mediante la comparación de métricas históricas de conversión contra las proyecciones del modelo.

2. Registro de Iteraciones del Prototipo

2.1 Versión 1.0 y 1.1: Intento Inicial e Implementación de Arquitectura Base

- **Descripción general:** Conceptualización del modelo base en scripts de Python aislados, seguido de la migración a una interfaz web utilizando Streamlit y su exposición mediante túneles locales (pyngrok).
- **Objetivo de la iteración:** Establecer la viabilidad técnica del entorno de ejecución y garantizar que el pipeline de preprocesamiento de datos (limpieza de CSV) pudiera integrarse en un flujo continuo.
- **Cambios realizados:** Empaquetado del código analítico dentro de la estructura de Streamlit.
- **Resultados obtenidos:** Ejecución exitosa del pipeline de datos en un entorno local y en Google Colab. El sistema logró leer el archivo de transacciones anonimizado.
- **Análisis crítico:** Desde el punto de vista algorítmico, esta versión carece de valor analítico. Se centró exclusivamente en resolver problemas de infraestructura (DevOps básicos). No hubo validación del comportamiento de los datos transaccionales ni normalización de las variables (escalado), lo que representa un punto ciego grave si se introduce K-Means directamente en este estado, dado que es sensible a la magnitud de las variables.
- **Conclusión de la versión:** Infraestructura no funcional con modelo matemático inexistente.
- **No incluye imágenes de resultados.**

2.2 Versión 1.2: Implementación de K-Means y Falla Metodológica (K Fijo)

- **Descripción general:** Primera implementación operativa del algoritmo K-Means sobre la base anonimizada 2025.
- **Objetivo de la iteración:** Agrupar a los clientes utilizando la matriz RFM calculada a partir del dataset.
- **Cambios realizados respecto a la versión anterior:** Se instanció el modelo KMeans de scikit-learn forzando el hiperparámetro de clústeres a un valor codificado (k=4).
- **Resultados obtenidos:** El algoritmo segmentó a los clientes en 4 grupos. Se generaron las primeras visualizaciones gráficas en la interfaz.
- **Análisis crítico:** Imponer un k=4 de manera arbitraria ("hardcoded") constituye un sesgo metodológico inaceptable en el aprendizaje no supervisado. Al no realizar un Análisis Exploratorio de Datos (EDA) profundo ni evaluar métricas de inercia intra-clúster, los resultados carecen de validez científica. El modelo agrupa los datos, pero no hay garantía de que esos 4 grupos representen la topología real y subyacente de la cartera de clientes.
- **Conclusión de la versión:** Versión funcional a nivel de software, pero analíticamente deficiente debido a decisiones arbitrarias en la parametrización.

Resultados:

Captura de imagen de prototipo

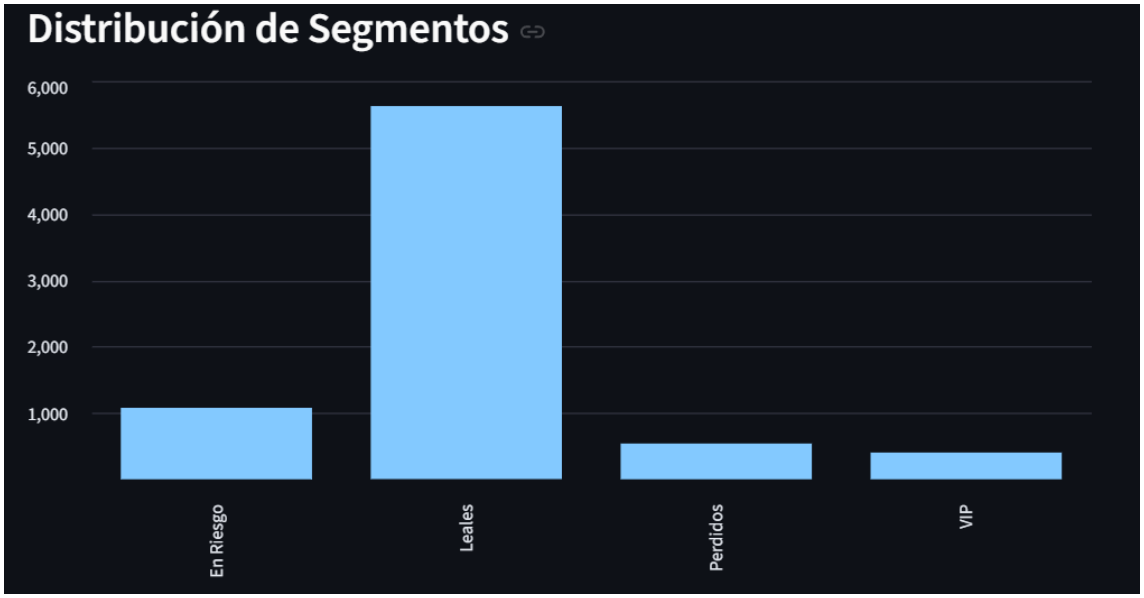

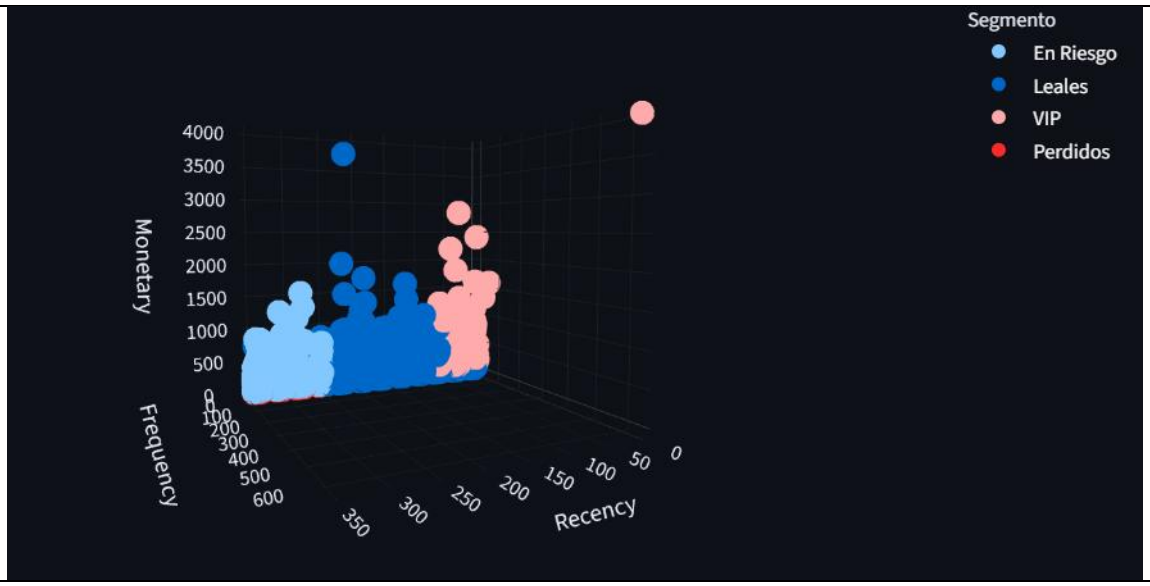

2.3 Versión 1.3 y 1.4: Parametrización Manual y Mejoras de Interfaz

- **Descripción general:** Modificación de la interfaz para permitir al usuario interactuar con el modelo y adición de lógicas de recomendación.
- **Objetivo de la iteración:** Otorgar flexibilidad al usuario final para experimentar con distintos números de segmentos e incluir un botón de ejecución explícito para optimizar recursos computacionales. Adicionalmente, se integraron recomendaciones de marketing estáticas.
- **Cambios realizados respecto a la versión anterior:** Sustitución del k=4 estático por un selector en la UI (st.slider o selectbox). Implementación de st.button para controlar la ejecución.
- **Resultados obtenidos:** Mayor interactividad. El usuario pudo forzar agrupaciones de 2 a N clústeres y observar cómo se redistribuían las masas de clientes y sus recomendaciones asociadas.
- **Análisis crítico:** Aunque mejora la Experiencia de Usuario (UX), empeora el rigor analítico. Delegar la elección de *K* al usuario, asumiendo que este tiene el criterio estadístico para definirlo a simple vista, es un error de diseño en herramientas de *Decision Support System* (DSS). El modelo sigue siendo ciego frente a la calidad del agrupamiento.

- **Conclusión de la versión:** Avance en usabilidad comercial, estancamiento en rigor estadístico.

Resultados:

Captura de imagen de prototipo
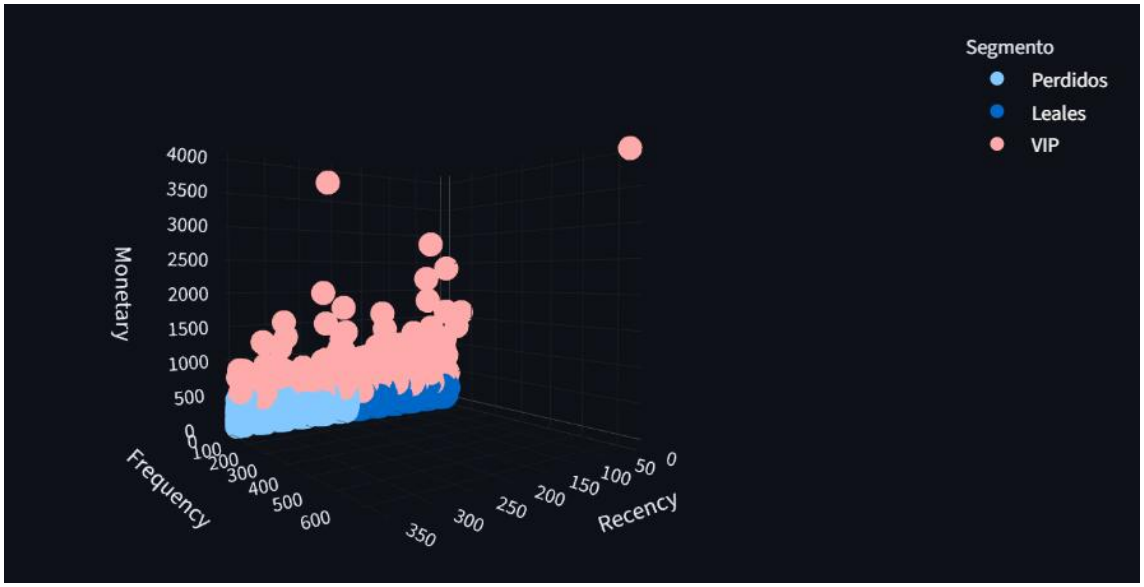

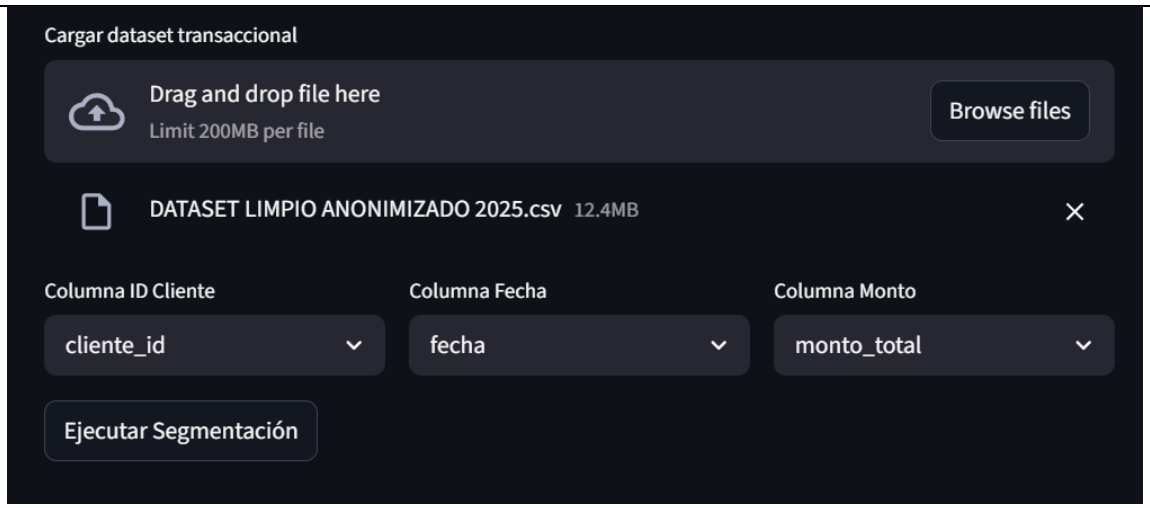
Cargar dataset transaccional
Drag and drop file here
Limit 200MB per file
Browse files
DATASET LIMPIO ANONIMIZADO 2025.csv 12.4MB
Columna ID Cliente
cliente_id
Columna Fecha
fecha
Columna Monto
monto_total
Ejecutar Segmentación

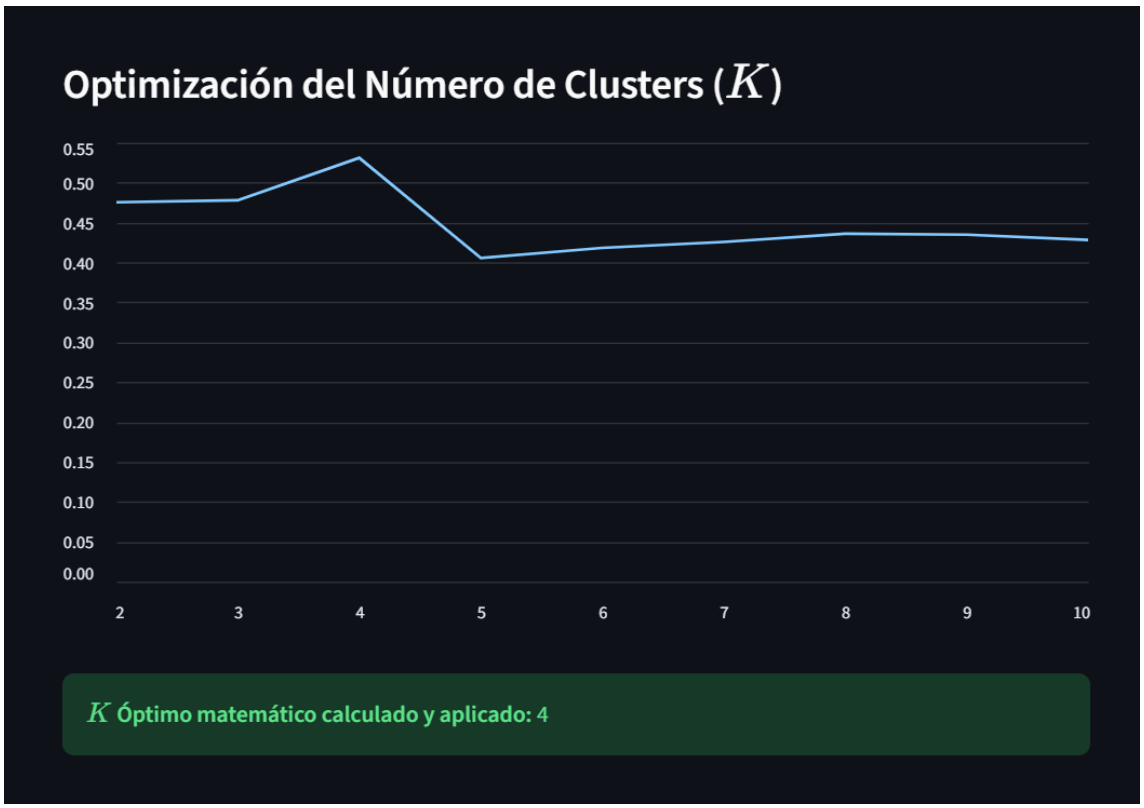
Optimización del Número de Clusters (K)
0.55
0.50
0.45
0.40
0.35
0.30
0.25
0.20
0.15
0.10
0.05
0.00
2
3
4
5
6
7
8
9
10
K Óptimo matemático calculado y aplicado: 4

Distribución de Segmentos

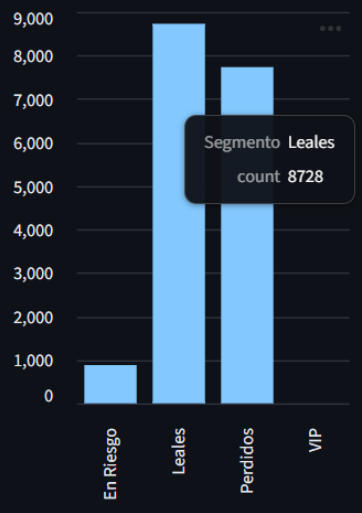

Topología 3D

Distribución RFM por Segmento

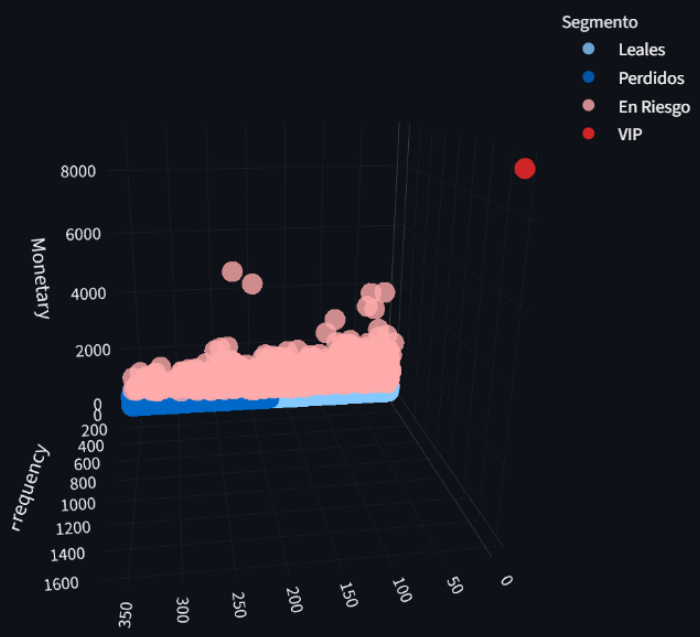

Recomendaciones de Marketing

Selecciona un segmento descubierto

VIP

- ✅ Promociones por frecuencia
- ✅ Cross-selling y up-selling
- ✅ Programa de puntos
- ✅ Comunicación periódica personalizada

2.4 Versión 1.5 y 1.6: Cálculo Automático de K Óptimo y Validación Visual

- **Descripción general:** Implementación del primer motor de evaluación heurística para determinar el hiperparámetro óptimo.
- **Objetivo de la iteración:** Eliminar el sesgo humano y calcular matemáticamente la cantidad óptima de segmentos basándose en la varianza de los datos.
- **Cambios realizados respecto a la versión anterior:** Se programó un bucle iterativo que evalúa diferentes valores de *K* utilizando el método del Codo (Elbow Method) y se reincorporó un gráfico para visualizar este cálculo óptimo.
- **Resultados obtenidos:** El sistema dejó de depender del usuario y comenzó a sugerir clústeres basados en la reducción de la inercia (Suma de Cuadrados Dentro del Clúster - WCSS).
- **Análisis crítico:** Es el primer salto cualitativo del prototipo. Sin embargo, el método del codo es notoriamente ambiguo en distribuciones de datos transaccionales ruidosos (como el retail), donde la curva rara vez presenta un punto de inflexión brusco o claro. Depender exclusivamente de la inercia puede llevar a subestimar la complejidad de los perfiles de consumo.
- **Conclusión de la versión:** Corrección del error arquitectónico de la V1.3, introduciendo automatización matemática básica.

Resultados:

Captura de imagen de prototipo
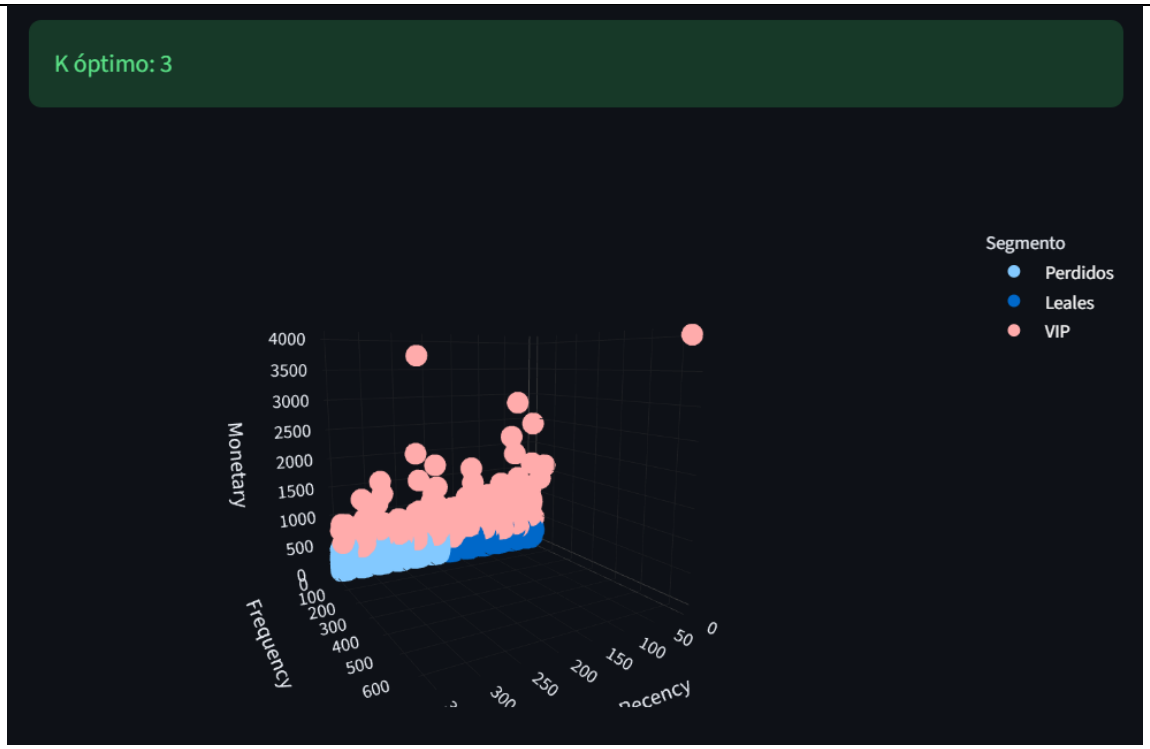 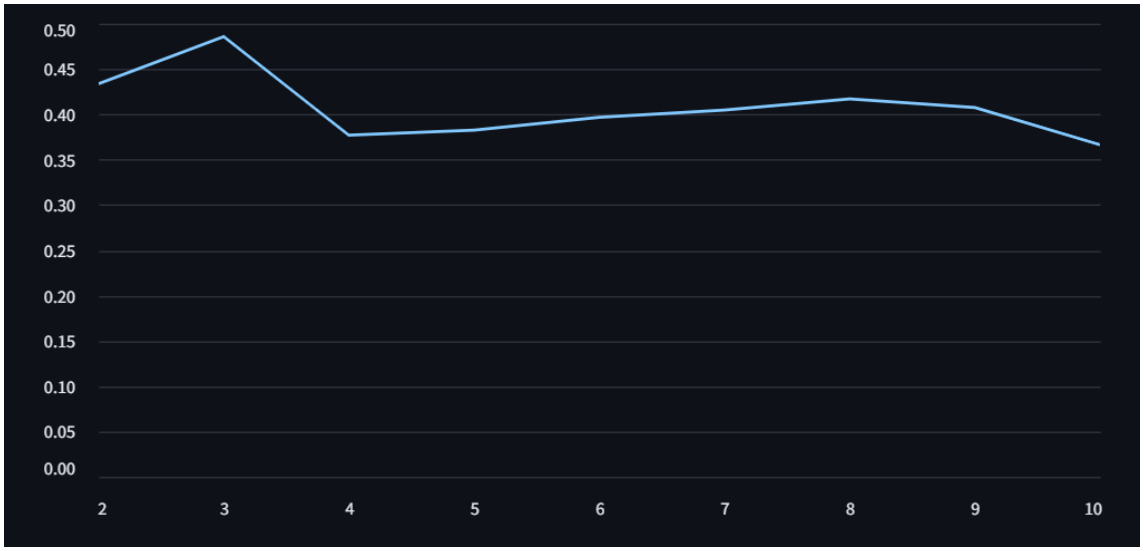

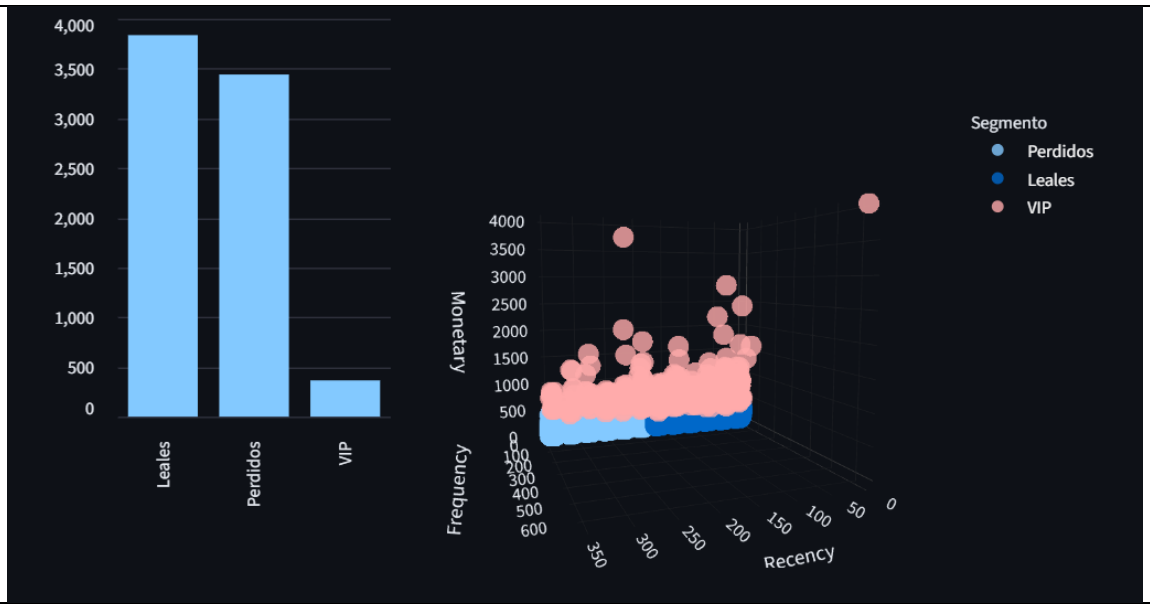

2.5 Versión 1.7: Introducción del Coeficiente Silhouette y Validación de Datos

- **Descripción general:** Transición hacia métricas de densidad y separación.
- **Objetivo de la iteración:** Cuantificar qué tan similar es un objeto a su propio clúster frente a otros clústeres, mejorando la robustez de la selección de *K*.
- **Cambios realizados respecto a la versión anterior:** Se integró el cálculo del silhouette_score. Se ajustó la lógica matemática para que el *K* óptimo maximice este coeficiente. Además, se agregó una tabla de validación de datos en crudo para auditar el dataset original.
- **Resultados obtenidos:** El modelo descartó segmentaciones espurias. El Silhouette Score evidenció que ciertas agrupaciones previamente sugeridas por el método del codo tenían un solapamiento severo (valores cercanos a 0).
- **Análisis crítico:** Una mejora metodológica sustancial. No obstante, el Silhouette Score favorece clústeres densos y esféricos (convexos). En datos RFM, donde la frecuencia y el valor monetario a menudo presentan asimetrías positivas (colas largas de pocos clientes que gastan mucho),

el Silhouette puede penalizar injustamente configuraciones válidas desde el punto de vista comercial.

- **Conclusión de la versión:** Alta fiabilidad matemática, pero con posibles fricciones frente a la realidad asimétrica de los datos de ventas.

Resultados:

Captura de imagen de prototipo
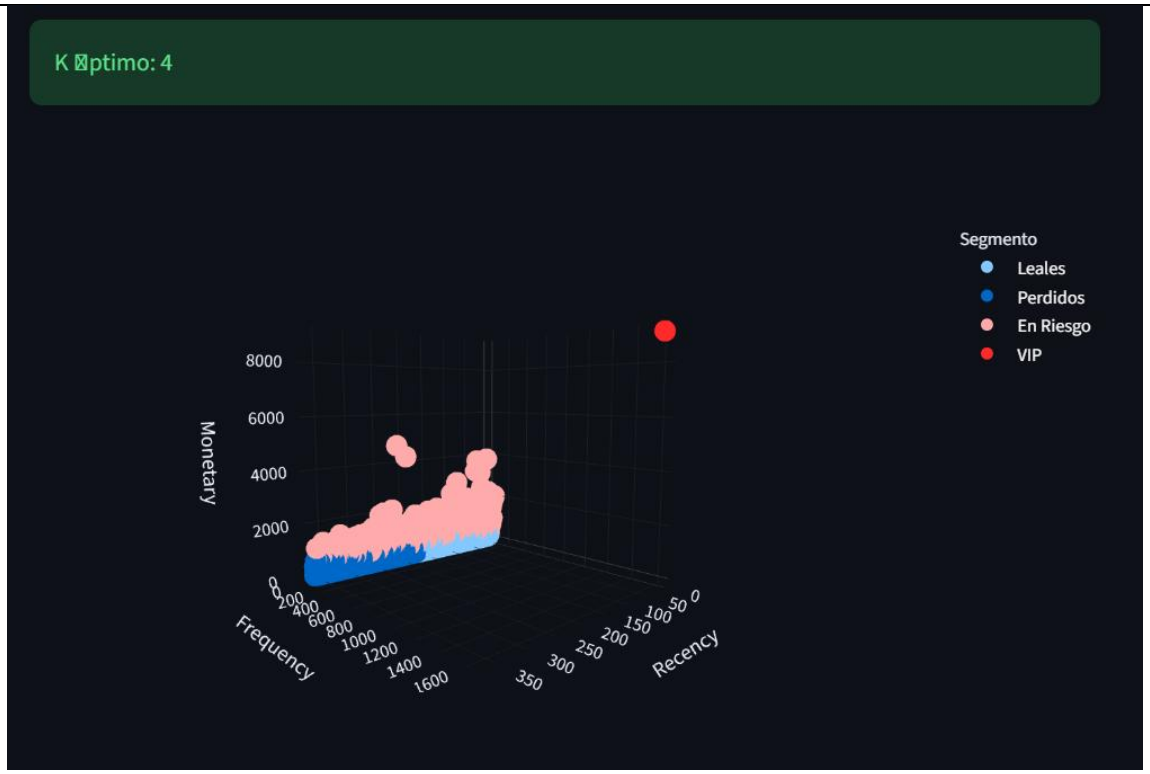

	cliente_id	Recency	Frequency	Monetary	Cluster	Segmento
3	00050C9EB7	269	1	173.83	1	Perdidos
4	00172DCAB2	361	2	17.26	1	Perdidos
5	002166BDD1	337	4	21.26	1	Perdidos
6	0022F5CCED	13	11	162.68	0	Leales
7	0026668859	59	1	112.96	0	Leales
8	002F52B30F	215	4	32.21	1	Perdidos
9	0032AB44C8	276	2	6.91	1	Perdidos
10	00348A95DA	248	5	57.08	1	Perdidos
11	0035B8BFC7	6	2	141.48	0	Leales
12	0035D432B3	32	9	874.56	3	En Riesgo
13	003C8B9990	74	4	19.69	0	Leales

2.6 Versión 1.8: Cross-Validación con Índice Davies-Bouldin

- **Descripción general:** Incorporación de una segunda métrica de validación de clústeres para contrarrestar los puntos ciegos del Silhouette.
- **Objetivo de la iteración:** Obtener una evaluación integral combinando la cohesión interna y la separación externa de los centroides.
- **Cambios realizados respecto a la versión anterior:** Se introdujo davies_bouldin_score de la librería sklearn.metrics. La selección del *K* óptimo pasó a ser un consenso o promedio ponderado entre minimizar Davies-Bouldin y maximizar Silhouette.
- **Resultados obtenidos:** Segmentaciones considerablemente más estables frente a valores atípicos (outliers) en los montos de transacción.
- **Análisis crítico:** Esta iteración demuestra madurez investigativa. Al cruzar dos métricas con naturalezas matemáticas distintas (una basada en distancias punto a punto y otra basada en dispersión de centroides), se mitiga el riesgo de falsos positivos en la selección del modelo. Es un diseño altamente robusto.
- **Conclusión de la versión:** El modelo alcanza madurez estadística y capacidad de auto-optimización robusta.

Resultados:

Captura de imagen de prototipo
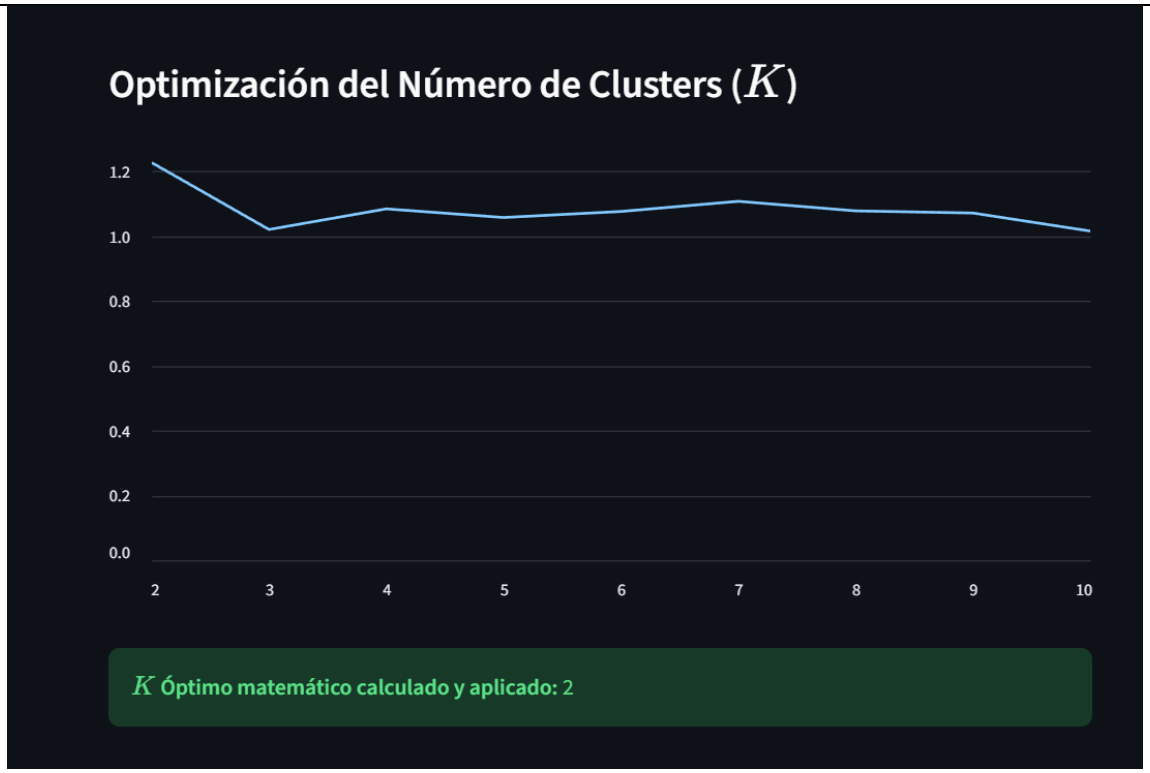
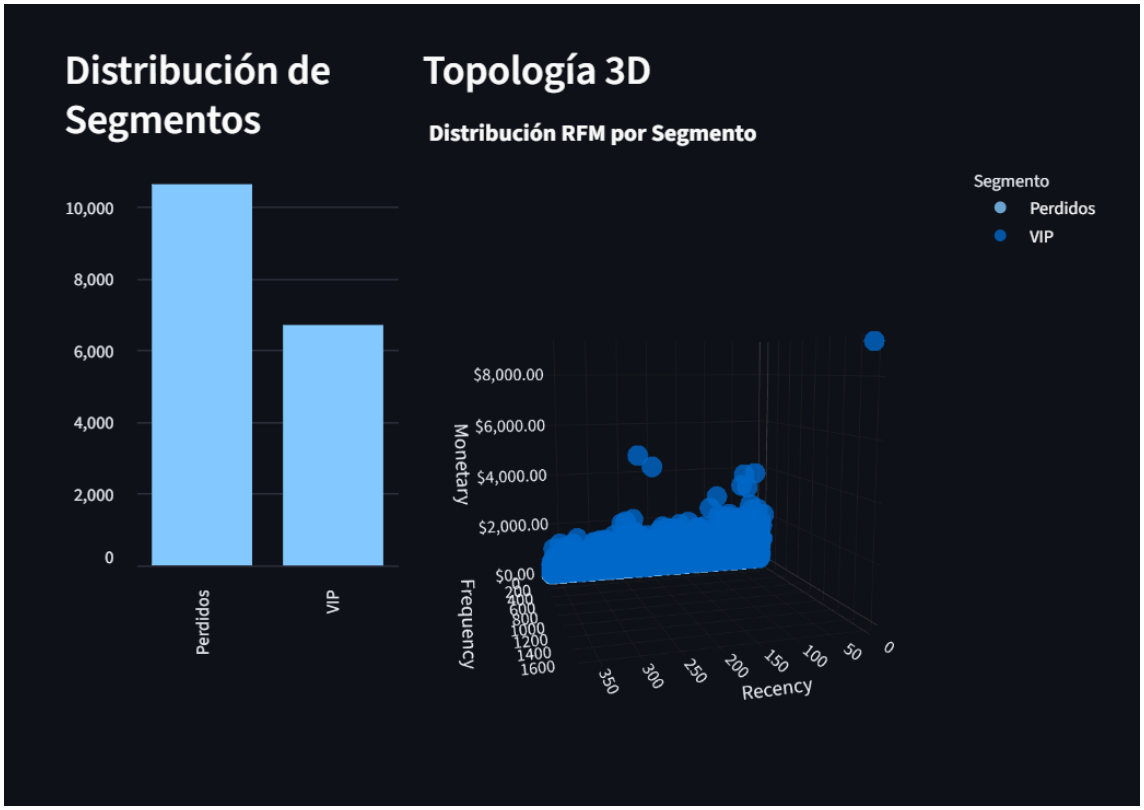

Distribución de Segmentos

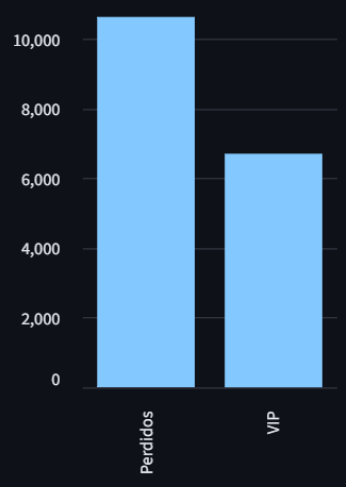

Topología 3D

Distribución RFM por Segmento

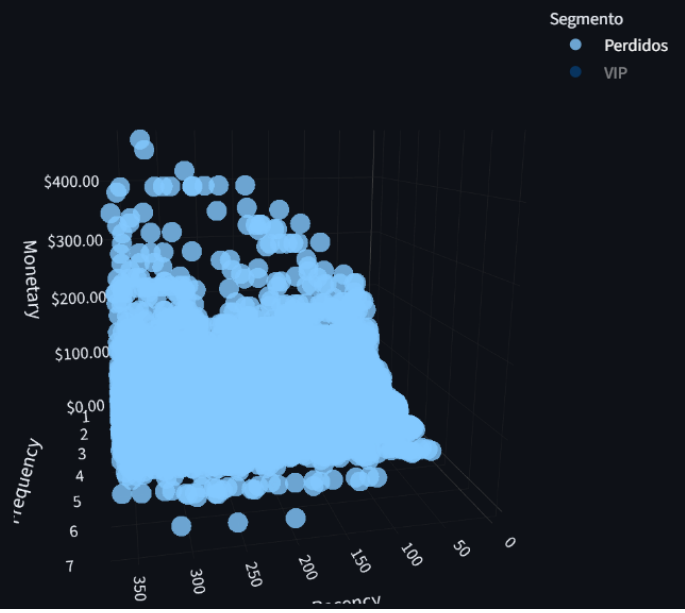

Recomendaciones de Marketing

Selecciona un segmento descubierto

Perdidos

- ✅ Campañas de recuperación de bajo costo
- ✅ Ofertas de reenganche
- ✅ Excluir de campañas costosas
- ✅ Depuración del CRM

Transacciones del segmento: Perdidos

	cliente_id	nombre_del_cliente	fecha	tienda	cantidad	descripcion
0	BDE7FC47CA	Den****ra	2025-01-02 00:00:00	Cajero Plaza	1	[22475926] PARAG
1	D5D300B2D3	Cap****re	2025-01-02 00:00:00	Cajero Plaza	1	[FC4500460] LAMP
2	E78300F894	Pau****ra	2025-01-02 00:00:00	Cajero Plaza	1	[257190] CANDELA
3	E78300F894	Pau****ra	2025-01-02 00:00:00	Cajero Plaza	1	[IC1003-14] CANDE
4	E78300F894	Pau****ra	2025-01-02 00:00:00	Cajero Plaza	1	[FUN2002] FUNDA
5	9B02394ECD	Pat****ez	2025-01-02 00:00:00	Cajero Plaza	1	[HZ1940130] CAJA

2.7 Versión 1.9: Penalización Matemática y Alineación Comercial (K=3)

- **Descripción general:** Intervención algorítmica final para ajustar la salida matemática a la operabilidad real del negocio (asimetría).
- **Objetivo de la iteración:** Evitar que el modelo optimizado de la V1.8 genere clústeres matemáticamente perfectos pero inmanejables para un departamento de marketing (ej. *K=2* demasiado genérico o *K=6* demasiado amplio).
- **Cambios realizados respecto a la versión anterior:** Se introdujo una función de "penalización matemática" en la evaluación de los scores. Si el algoritmo tiende a desviarse de *K=3* (la estructura clásica de RFM: Clientes de Valor, Promedio, y en Riesgo), se le aplica un peso negativo ligero para forzar la convergencia hacia 3 clústeres, a menos que la evidencia estadística para otro *K* sea abrumadora.
- **Resultados obtenidos:** El prototipo converge consistentemente en 3 clústeres de alto valor interpretativo. Generación exitosa de tableros consolidados con estrategias accionables (marketing_recommendations) para el segmento seleccionado.

Resultados:

Captura de imagen de prototipo
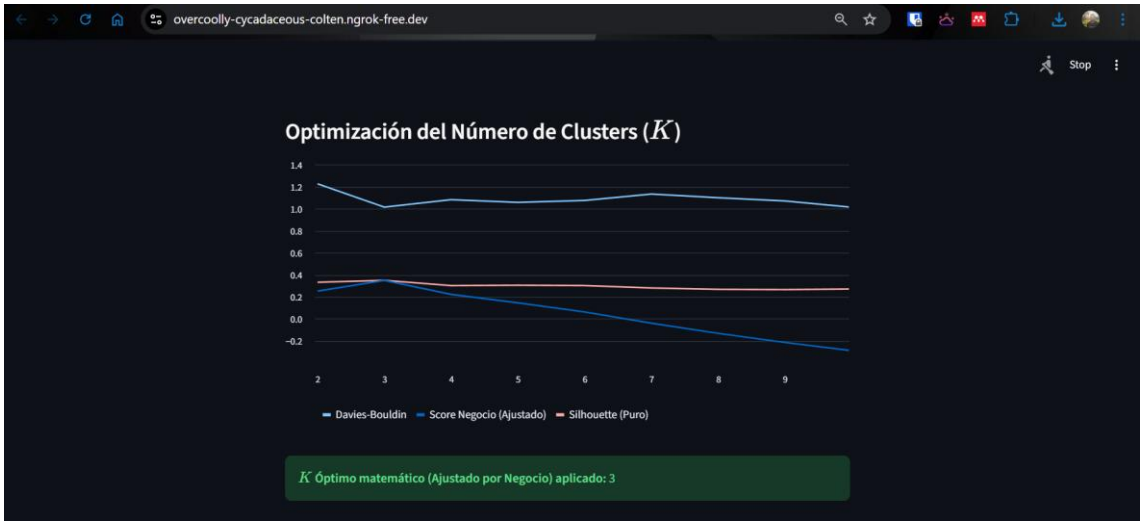

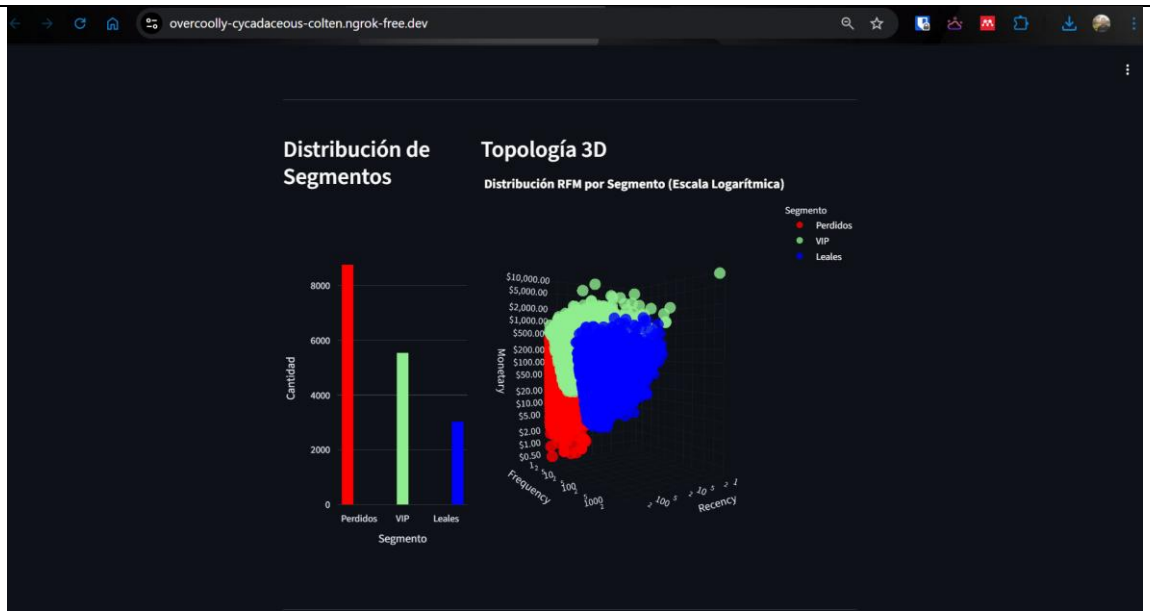

Evidencia de ejecución - Versión 1.9:

- **Análisis crítico:** A nivel puramente académico y purista, introducir una penalización ad-hoc introduce sesgo. Sin embargo, desde la perspectiva de la Ciencia de Datos Aplicada, es una decisión brillante. Reconoce que el objetivo final de la tesis no es encontrar agrupaciones abstractas, sino **generar valor accional para el sector retail**. Calibrar el modelo para preferir soluciones operativas (3 segmentos claros) demuestra comprensión profunda del dominio del problema.

- **Conclusión de la versión:** El prototipo alcanza su versión Release Candidate (RC). Es un equilibrio óptimo entre rigor algorítmico y pragmatismo empresarial.

3. Conclusión General

El seguimiento longitudinal de las versiones 1.0 a 1.9 del prototipo evidencia una curva de madurez técnica pronunciada. El proyecto inició con una arquitectura deficiente donde las decisiones de modelado se basaban en suposiciones arbitrarias (hardcoding de clústeres en V1.2) y delegación irresponsable de carga cognitiva al usuario (V1.3).

No obstante, la evolución demuestra una capacidad crítica para iterar sobre los propios errores metodológicos. La inclusión progresiva de la evaluación heurística, la optimización por coeficiente de Silhouette (V1.7) y la validación cruzada con el Índice Davies-Bouldin (V1.8) transformaron un simple script en un motor analítico robusto.

El mayor aprendizaje y logro técnico del prototipo se materializa en la Versión 1.9. Al comprender que los algoritmos no supervisados ignoran el contexto del negocio, la implementación de la penalización matemática para favorecer clústeres operativos (K=3) demuestra un dominio que trasciende la programación básica. El resultado es un artefacto de software que no solo es metodológicamente sólido, sino directamente aplicable a la resolución del problema de segmentación masiva en el marco transaccional ecuatoriano.

4. Bibliografía Seleccionada

1. Paramita, A. S., & Hariguna, T. (2024). Comparative Studies on Clustering Algorithms K-Means and DBSCAN. Journal of Digital Market and Digital Currency. [1]
2. Gan, W., Zhou, P., Wan, S., & Zeng, J. (2025). RFMI-based Customer Segmentation with K-means. 2024 IEEE International Conference on Big Data. [2]
3. John, J. M., Shobayo, O., & Ogunleye, B. (2025). The RFM-A Model: Combining Behavioral and Demographic Data for Segmentation. The Journal of Supercomputing. [3]
4. Srivastava, P., & Saxena, D. S. (2025). Enhanced Customer: A Comparative Analysis of Leading Clustering Algorithms. International Journal of Novel Research and Development, 10(4). [4]
5. Nugroho, B. I., Rafhina, A., & Ananda, P. S. (2024). Customer segmentation in sales transaction data using k-means clustering algorithm. Journal of Intelligent Decision Support System, 7(2). [5]
6. Hidayat, T., Ruldeviyani, A., & Aditama, A. R. (2024). Optimal Use of Customer Segmentation using RFM and K-means. Scientific Journal of Informatics, 11(1). [6]
7. Lai, M. T. (2025). Comparison of K-Means and DBSCAN Algorithms for Customer Segmentation. ResearchGate. [7]
8. Lewaaelhamd, I. (2024). Customer segmentation using machine learning model: An application of RFM analysis. Journal of Data Science and Intelligent Systems, 2, 29–36. [8]
9. Nithyashree, R. (2024). Decoding Decision Support Systems: Empowering Malls with Customer Segmentation. Medium Data Science. [9]
10. Ogunleye, B. (2024). An Exploration of Clustering Algorithms for Customer Segmentation in the UK Retail Market. Analytics, 2(4), 809-823. [10]