# S5-INFORME DE RESULTADOS

**INTEGRANTES**:

- ALFREDO MALDONADO
- LUIS RIOS
- CRISTHIAN VELEZ

Fecha: 13 de FEB. de 25

Contenido

**1. Objetivo General** ..... 3

**1.1 Objetivos Específicos** ..... 3

**2. Informe Técnico Preliminar: Prototipo y Modelo Baseline (RFM + K-Means)** ..... 4

**2.1 Descripción del prototipo y del baseline** ..... 4

**2.2 Métricas y resultados obtenidos** ..... 4

**2.3 Análisis crítico de resultados** ..... 6

**2.3.1 Línea de tiempo de errores y blind spots técnicos** ..... 6

**2.3.2 Fortalezas y limitaciones** ..... 6

**2.3.3 Relación con el problema organizacional** ..... 7

**2.4 Propuesta de próximos pasos** ..... 7

**3. Bibliografía Seleccionada** ..... 8

# 1. Objetivo General

Desarrollar un prototipo de sistema de segmentación de clientes utilizando algoritmos de aprendizaje no supervisado (K-Means) para identificar perfiles de consumo diferenciados y optimizar la efectividad de las campañas de marketing en cadenas comerciales del sector retail, permitiendo una transición de estrategias masivas a acciones personalizadas basadas en datos transaccionales, bajo el marco legal de protección de datos en el Ecuador.

## 1.1 Objetivos Específicos

1. **Ejecutar el proceso de extracción, limpieza y preprocesamiento de datos** del historial transaccional en un periodo de dos semanas, calculando las métricas de Recencia, Frecuencia y Valor Monetario (RFM) para construir la base de conocimiento del modelo.y Determinar el número óptimo de clústeres *(k)* mediante la aplicación de técnicas de validación estadística como el Método del Codo y el Coeficiente de Silueta en un plazo de dos semanas, asegurando la cohesión interna y separación de los segmentos identificados.
2. **Implementar y entrenar el algoritmo K-Means** utilizando Python y Scikit-learn durante un ciclo de cinco semanas, logrando una clasificación de la base de clientes en segmentos accionables para el negocio (VIP, Leales, Ocasionales, En Riesgo O Similares).
3. **Construir un dashboard interactivo de visualización** mediante Streamlit en un periodo de tres semanas, que integre los resultados del modelo y permita a los gerentes de marketing explorar las características de cada segmento para el diseño de campañas. y Evaluar el impacto potencial del prototipo mediante la comparación de métricas históricas de conversión contra las proyecciones del modelo.

# 2. Informe Técnico Preliminar: Prototipo y Modelo Baseline (RFM + K-Means)

## 2.1 Descripción del prototipo y del baseline

- Objetivo del prototipo: Desarrollar un sistema interactivo que automatice la segmentación de clientes basándose en su historial transaccional para prescribir estrategias de marketing personalizadas.
- Modelo baseline implementado: Clustering no supervisado utilizando el algoritmo K-Means aplicado sobre variables RFM (Recencia, Frecuencia, Monto). Se fijó inicialmente k=4 como línea base para categorizar en: VIP, Leales, En Riesgo y Perdidos.
- Conjunto de datos: Se utilizó un dataset de pruebas (retail_sales_dataset.csv) consistente en 1000 transacciones sintéticas para validar la lógica del pipeline. El dataset real de la empresa ecuatoriana se encuentra actualmente en fase de validación y anonimización para cumplir con la LOPDP.
- Contexto de evaluación: El modelo se probó en un entorno de desarrollo en la nube (Google Colab), exponiendo el frontend mediante túneles (ngrok) para simular la interacción del usuario final (departamento de marketing).l modelo se evaluó a través de un dashboard interactivo en Streamlit ejecutado desde Google Colab, permitiendo simular la experiencia del usuario final (analista de marketing) al cargar datos y visualizar clústeres en 3D.

## 2.2 Métricas y resultados obtenidos

Al tratarse de un modelo no supervisado, la evaluación inicial se centra en la cohesión y separación de los clústeres, así como en la viabilidad de la distribución.

- Métricas técnicas: Se implementó el Silhouette Score para evaluar la densidad y separación de los agrupamientos sobre el espacio RFM estandarizado.

- Resultados preliminares: * El modelo logró segmentar la base de pruebas identificando claramente los 4 grupos solicitados.
    - Distribución: La categorización mostró una distribución coherente (visualizada en el gráfico de barras del prototipo), donde los segmentos de extremos ("Riesgo" y "VIP") presentan perfiles de gasto y frecuencia diametralmente opuestos.
- Evidencia: Las capturas de resultados respaldan la correcta separación geométrica en el gráfico de dispersión 3D (Recency vs Frequency vs Monetary).

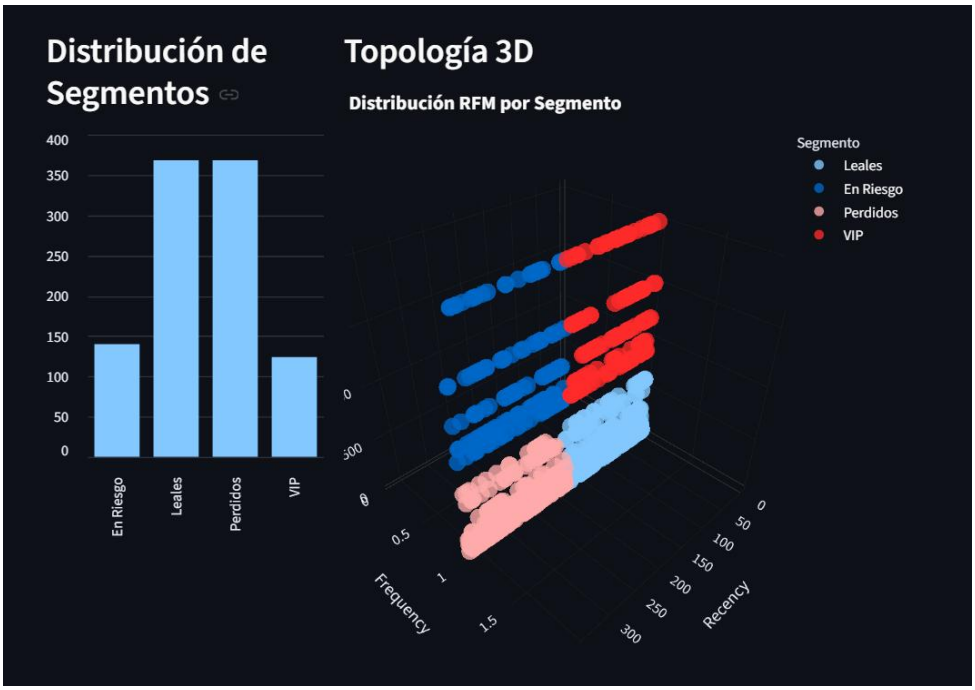


Grafico 1: Gráfico de dispersión 3D

Gráfico 2: Recomendaciones Marketing pruebas.

## 2.3 Análisis crítico de resultados

Este apartado expone las deficiencias técnicas encontradas durante las primeras iteraciones y evalúa el enfoque actual.

### 2.3.1 Línea de tiempo de errores y blind spots técnicos

El desarrollo evidenció severos puntos ciegos en la validación de datos y arquitectura de despliegue:

1. V1.0 - V1.1 (Despliegue fallido): Se intentó usar LocalTunnel para exponer la aplicación de Streamlit. Resultó en un bloqueo de red (pantalla de carga infinita) y errores ERR_NGROK_121 al intentar transicionar mal entre herramientas.

   Falla: Dependencia de túneles inestables para un entorno que requiere presentación continua. Se solucionó migrando definitivamente a Ngrok con autenticación de token.

2. V1.2 (Quiebre del pipeline de datos): El modelo colapsó con un error fatal: TypeError: datetime64 type does not support sum operations. Análisis de la falla: El código asumía ciegamente que la columna mapeada por el usuario en el frontend era numérica. Al aplicar .agg('sum') en el cálculo RFM, el sistema intentó sumar fechas. Esto demostró una total falta de programación defensiva y sanitización de datos (Data Sanitization). Se corrigió forzando coerciones de tipo (pd.to_numeric, pd.to_datetime) antes del agrupamiento.

### 2.3.2 Fortalezas y limitaciones

- Fortalezas: El pipeline actual es modular. La extracción de RFM está aislada del modelado K-Means, lo que permite cambiar el algoritmo en el futuro. La interfaz proporciona prescripciones accionables instantáneas.
- Limitaciones: El preprocesamiento actual es muy básico. Asumir *k=4* estático fuerza la distribución de datos; si la varianza es baja, el modelo inventará fronteras artificiales. Además, no se están utilizando variables

demográficas presentes en el dataset (Edad, Categoría de Producto), perdiendo poder predictivo.

### 2.3.3 Relación con el problema organizacional

El modelo base cumple la premisa fundamental: abandonar el marketing masivo. Los resultados muestran que es posible identificar a los clientes "En Riesgo" a tiempo para lanzar campañas de recuperación antes de que se conviertan en "Perdidos", impactando directamente en la métrica de retención del negocio.

## 2.4 Propuesta de próximos pasos

El prototipo actual es funcional pero frágil. Se deben priorizar las siguientes acciones:

Ajustes técnicos al modelo:

1. Integrar el Método del Codo (Elbow Method) y Silhouette visual de forma dinámica para que *k* no sea un número estatico (harcoded a 4), sino que responda a la topología de los datos.
2. Manejo de Outliers: Implementar un filtro (ej. IQR o Z-score) en el preprocesamiento, ya que K-Means es extremadamente sensible a valores atípicos monetarios.

Mejoras en el enfoque metodológico:

1. Transicionar del dataset de pruebas al dataset real de la empresa y re-evaluar la varianza.
2. Añadir variables categóricas (Categoría de producto preferida) utilizando K-Prototypes en lugar de K-Means, o generar clusters anidados.

Actualización del Backlog (Priorizado):

1. [Alta] Integrar validación de datos estricta en la subida del CSV (rechazar archivos mal formateados con mensajes claros en UI).
2. [Alta] Implementar gráfico del Codo dinámico en Streamlit.

3. [Media] Procesar dataset de la empresa y ajustar parámetros de estandarización.
4. [Baja] Diseñar el esquema de prueba A/B para medir el impacto de las campañas generadas por los clústeres.

## 3. Bibliografía Seleccionada


1. Paramita, A. S., & Hariguna, T. (2024). Comparative Studies on Clustering Algorithms K-Means and DBSCAN. Journal of Digital Market and Digital Currency. [1]
2. Gan, W., Zhou, P., Wan, S., & Zeng, J. (2025). RFMI-based Customer Segmentation with K-means. 2024 IEEE International Conference on Big Data. [2]
3. John, J. M., Shobayo, O., & Ogunleye, B. (2025). The RFM-A Model: Combining Behavioral and Demographic Data for Segmentation. The Journal of Supercomputing. [3]
4. Srivastava, P., & Saxena, D. S. (2025). Enhanced Customer: A Comparative Analysis of Leading Clustering Algorithms. International Journal of Novel Research and Development, 10(4). [4]
5. Nugroho, B. I., Rafhina, A., & Ananda, P. S. (2024). Customer segmentation in sales transaction data using k-means clustering algorithm. Journal of Intelligent Decision Support System, 7(2). [5]
6. Hidayat, T., Ruldeviyani, A., & Aditama, A. R. (2024). Optimal Use of Customer Segmentation using RFM and K-means. Scientific Journal of Informatics, 11(1). [6]
7. Lai, M. T. (2025). Comparison of K-Means and DBSCAN Algorithms for Customer Segmentation. ResearchGate. [7]
8. Lewaaelhamd, I. (2024). Customer segmentation using machine learning model: An application of RFM analysis. Journal of Data Science and Intelligent Systems, 2, 29–36. [8]
9. Nithyashree, R. (2024). Decoding Decision Support Systems: Empowering Malls with Customer Segmentation. Medium Data Science. [9]
10. Ogunleye, B. (2024). An Exploration of Clustering Algorithms for Customer Segmentation in the UK Retail Market. Analytics, 2(4), 809-823. [10]