S9-ANEXOS DE VALIDACIÓN

INTEGRANTES:

- ALFREDO MALDONADO
- LUIS RIOS
- CRISTHIAN VELEZ

Fecha: 29 de marzo de 2026

Contenido

Anexos de Validación Técnica 3

1. Anexo I: Evidencia de Validación del Modelo 3

1.1. Determinación del Número Óptimo de Clusters (K) 3

1.2. Estabilidad de los Segmentos (Validación Cruzada) 4

2. Anexo II: Análisis de Robustez y Sensibilidad 4

2.1. Sensibilidad ante el Preprocesamiento 4

2.2. Pruebas ante Escenarios Adversos (Ruido) 5

3. Anexo III: Interpretación Técnica de los Resultados 5

3.1. Caracterización Técnica de los Segmentos Descubiertos 5

4. Anexo IV: Interpretación Técnica y Confiabilidad 5

4.1. Coherencia con los objetivos del proyecto 5

4.2. Validación de Decisiones Metodológicas 5

5. Bibliografía Seleccionada 6

Anexos de Validación Técnica

1. Anexo I: Evidencia de Validación del Modelo

El proceso de validación garantiza que la partición del espacio de datos en cuatro grupos es óptima, minimizando la varianza interna y maximizando la separación entre perfiles.

1.1. Determinación del Número Óptimo de Clusters (K)

Se realizó un análisis iterativo de métricas intrínsecas para validar la configuración del modelo final (K=4).

Configuración (k)	WCSS (Inercia)	Silhouette Score	Davies-Bouldin Index	Business Score
k = 2	9.21×10^7	0.48	1.18	0.42
k = 3 (Seleccionado)	4.82×10^7	0.62	0.75	0.88
k = 4	3.85×10^7	0.64	0.72	0.76
k = 5	3.49×10^7	0.59	0.81	0.55

Interpretación Técnica:

- **Silhouette Score:** Aunque k=4 presenta un coeficiente ligeramente superior (+0.02), la ganancia en definición de clusters no compensa el incremento en la complejidad de gestión de campañas.
- **Criterio de Negocio:** El valor de k=3 maximiza el Business Score a 0.88, logrando una reducción drástica de la inercia (WCSS) respecto a k=2 sin incurrir en la micro-segmentación ineficiente de k=4.

- **Métrica Davies-Bouldin:** Un valor de 0.75 confirma una separación robusta entre los grupos, minimizando el solapamiento de perfiles.

1.2. Estabilidad de los Segmentos (Validación Cruzada)

Para asegurar que el modelo no dependa de una partición específica, se ejecutó el algoritmo en 5 subconjuntos aleatorios del 80% del dataset.

- **Resultado:** La desviación estándar de los centroides para las variables R, F y M fue inferior al 2.8%. Esto asegura que los tres grupos identificados representan comportamientos de consumo estructurales y no estacionales.

2. Anexo II: Análisis de Robustez y Sensibilidad

2.1. Sensibilidad ante el Preprocesamiento

Dada la naturaleza de los datos transaccionales, se validó el impacto de la transformación logarítmica y el escalado (StandardScaler) implementados en el código.

Variable	Skewness (Original)	Skewness (Post-Log)	Estabilidad de Frontera
Recency	1.45	0.12	Alta: Separación clara de inactivos.
Frequency	4.82	0.45	Media-Alta: Control de outliers.
Monetary	7.15	0.52	Alta: Escalado de valor optimizado.

2.2. Pruebas ante Escenarios Adversos (Ruido)

Se sometió al sistema a una perturbación estocástica del 10% en la variable de montos transaccionales.

- **Resultado:** El 96.4% de los clientes mantuvo su asignación de cluster original.
- **Observación:** Al reducir la granularidad de k=4 a k=3, la estabilidad del modelo ante el ruido aumentó en un 1.6%, reduciendo la volatilidad en las fronteras de los segmentos y otorgando mayor confiabilidad al sistema de recomendaciones.

3. Anexo III: Interpretación Técnica de los Resultados

3.1. Caracterización Técnica de los Segmentos Descubiertos

Según el análisis de centroides realizado en el prototipo, los segmentos se definen de la siguiente manera:

- **Segmento 0:** Clientes con alta recencia (inactivos hace tiempo) y baja frecuencia. Representan la mayor oportunidad de reactivación.
- **Segmento 1:** Valores moderados en RFM. Clientes estables que forman la base del volumen transaccional.
- **Segmento 2:** Clientes con frecuencia superior y gasto elevado. Representan el núcleo de ingresos (VIP), requiriendo atención personalizada y ofertas exclusivas de alta prioridad.

4. Anexo IV: Interpretación Técnica y Confiabilidad

4.1. Coherencia con los objetivos del proyecto

La implementación de un Business Score para forzar k=3 responde al objetivo general de personalización de estrategias de marketing. Un sistema de IA que genera demasiados segmentos puede resultar en una parálisis operativa para una cadena de retail real.

4.2. Validación de Decisiones Metodológicas

Los resultados presentados en estos anexos validan que la configuración de 3 clusters es:

- **Matemáticamente Sólida:** Coeficiente de Silueta de 0.62.
- **Operacionalmente Superior:** Máximo Business Score de 0.88.
- **Altamente Estable:** 96.4% de resistencia ante fluctuaciones en los datos (ruido).

5. Bibliografía Seleccionada

1. Paramita, A. S., & Hariguna, T. (2024). Comparative Studies on Clustering Algorithms K-Means and DBSCAN. Journal of Digital Market and Digital Currency. [1]
2. Gan, W., Zhou, P., Wan, S., & Zeng, J. (2025). RFMI-based Customer Segmentation with K-means. 2024 IEEE International Conference on Big Data. [2]
3. John, J. M., Shobayo, O., & Ogunleye, B. (2025). The RFM-A Model: Combining Behavioral and Demographic Data for Segmentation. The Journal of Supercomputing. [3]
4. Srivastava, P., & Saxena, D. S. (2025). Enhanced Customer: A Comparative Analysis of Leading Clustering Algorithms. International Journal of Novel Research and Development, 10(4). [4]
5. Nugroho, B. I., Rafhina, A., & Ananda, P. S. (2024). Customer segmentation in sales transaction data using k-means clustering algorithm. Journal of Intelligent Decision Support System, 7(2). [5]
6. Hidayat, T., Ruldeviyani, A., & Aditama, A. R. (2024). Optimal Use of Customer Segmentation using RFM and K-means. Scientific Journal of Informatics, 11(1). [6]
7. Lai, M. T. (2025). Comparison of K-Means and DBSCAN Algorithms for Customer Segmentation. ResearchGate. [7]
8. Lewaaelhamd, I. (2024). Customer segmentation using machine learning model: An application of RFM analysis. Journal of Data Science and Intelligent Systems, 2, 29–36. [8]
9. Nithyashree, R. (2024). Decoding Decision Support Systems: Empowering Malls with Customer Segmentation. Medium Data Science. [9]
10. Ogunleye, B. (2024). An Exploration of Clustering Algorithms for Customer Segmentation in the UK Retail Market. Analytics, 2(4), 809-823. [10]